

BASiS:

ベイズ的データ選別による目的特化対話システムの会話行動適応

ANONYMOUS AUTHOR(S)

本論文では、小規模で高品質なコーパスに基づくベイズ的データ選別を通じて、目的特化対話に求められる会話スタイルへローカル大規模言語モデル（LLM）を適応させる手法BASiS（Bayesian Style-based Selection）を提案する。近年のLLMは、流暢かつ正確な応答を生成できるようになった。一方、感情支援、数学チュータリング、医療問診などの場面では、正しい内容を提示するだけでなく、適切な方法で応答することが求められる。このような会話スタイルは、小規模な対話コーパスに表れていることが多いが、それらをそのままLLMの学習に用いるにはデータ量が限られている。大規模な汎用対話コーパスは十分なデータ量を持つ一方で、目的の会話スタイルに適合する事例を十分に含んでいるとは限らない。BASiSは、小規模コーパスから会話状態、応答戦略、状態遷移を抽出し、それらをベイズ的対話モデルとして表現する。次に、大規模コーパスに含まれる対話を、目的の会話スタイルへの適合度に基づいてスコアリングし、学習データを選別する。さらに、選別したデータから選好ペアを構築し、Direct Preference Optimization（DPO）を用いてLLMを学習する。BASiSの主な利点は、小規模コーパスに暗黙的に含まれる対話の進め方を、より大規模なコーパスから適切なデータを特定するための選別基準へ変換する点にある。これにより、詳細な対話ガイドラインを手で設計する負担を軽減しながら、一般的な品質や話題の類似性だけでは捉えにくい応答のタイミングや複数ターンにわたる対話の進行を、データ選別に反映できる。また、単一の応答戦略に固定するのではなく、会話状態を確率分布として保持することで、同一の文脈に対する複数の妥当な応答戦略を維持できる。感情支援、数学チュータリング、医療問診を対象として、学習前のベースモデル、BASiSによる選別データで学習したモデル、および目的コーパスのカテゴリ内から無作為に選別したデータで学習したモデルを比較することで、BASiSを評価した。その結果、三つの実験設定すべてにおいて、BASiSによる選別データで学習したモデルが、目的コーパスに特徴的な応答方針と対話の進行を再現する評価で最も高いスコアを示した。

CCS Concepts: • **Computing methodologies** → **Natural language generation**; **Discourse, dialogue and pragmatics**; Learning from implicit feedback; • **Human-centered computing** → **Natural language interfaces**.

Additional Key Words and Phrases: 目的特化対話システム, 会話スタイル, データ選別, ベイズ的対話モデリング, 選好最適化, 感情支援対話, 大規模言語モデル

ACM Reference Format:

Anonymous Author(s). 2026. BASiS:ベイズ的データ選別による目的特化対話システムの会話行動適応. In *Proceedings of 32nd Annual ACM Conference on Intelligent User Interfaces (IUI '27)*. ACM, New York, NY, USA, 17 pages.

1 はじめに

Instruction tuningやRLHFの発展により、近年の大規模言語モデル（LLM）は、指示に従って正確な応答を生成し、多様な話題について自然で一貫した複数ターン対話を行えるようになった[11]。一方、感情支援、数学チュータリング、医療問診などの目的特化対話では、正しい情報を提示するだけでなく、相手の状態や対話の段階に応じて適切な応答方針を選ぶ必要がある[7, 13]。例えば、相手の感情を受け止めてから助言へ移ること、学習者自身の推論を促すこと、必要な症状を適切な順序で聞き出すことが求められる。このよ

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM.

Manuscript submitted to ACM

Manuscript submitted to ACM

うな会話スタイルは、目的に沿って構築された小規模高品質コーパスに表れているが、そのままLLMの学習に用いるにはデータ量が限られる。これに対し、大規模汎用コーパスはデータ量と多様性に優れるものの、目的の会話スタイルに適合する対話を十分に含むとは限らない。そこで、小規模高品質コーパスに含まれる会話スタイルを利用し、大規模汎用コーパスから目的に適した対話データを選別する方法が必要となる。

目的特化対話に適した応答を生成するため、既存研究では複数のアプローチが検討されている。ガイドラインに基づく応答制御では、望ましい対話方針をあらかじめ明示的に定義し、その方針に従うように応答生成を制御する。WenらのGuidedTODは、タスク指向対話の流れを確率的に表現し、対話の進行に応じてガイドラインに基づく方針を更新しながら応答候補を再ランキングすることで、既存手法よりも高いガイドライン遵守性能を示した[16]。また、対話状態に基づく応答戦略予測では、現在のユーザ状態から次に取るべき応答戦略を推定する。WanらのEmoDynamixは、ユーザの複数の感情状態と応答戦略の関係を異種グラフとしてモデル化し、高い戦略予測性能と戦略選択過程の解釈可能性を示した[15]。さらに、LLMの学習に用いるデータの選別に関する研究では、少量であっても高品質なデータを適切に選ぶことで、効率的にモデルの振る舞いを調整できることが示されている[18, 21]。

しかし、これらの既存研究には三つの課題がある。第一に、ガイドラインに基づく応答制御では、目的や領域ごとに望ましい対話方針を手手で記述する必要がある。会話のトーン、応答のタイミング、複数ターンにわたる対話の進め方など、コーパスに暗黙的に表れる会話スタイルを網羅的なルールとして明示することは難しい。第二に、応答戦略予測では、一般に現在の状態に対して次を取る単一の戦略を予測する。しかし、実際の対話では、同一の文脈に対して、共感を続ける、質問によって掘り下げる、情報を整理するといった複数の戦略が妥当になり得る。この場合、単一の予測結果だけでは、目的コーパスに含まれる応答の多様性を十分に表現できない。第三に、既存のデータ選別手法の多くは、応答の正確さ、有用性、多様性、タスクの網羅性といった一般的な品質を基準とする。しかし、一般的な品質が同程度でも、応答のタイミングや、応答後の会話状態の遷移が異なれば、目的コーパスの会話スタイルへの適合度も異なる。会話履歴や応答戦略の遷移を評価基準に含めなければ、目的コーパスに特徴的な対話の流れを保持したデータを安定して選別することは難しい。

これらの課題を解決するため、本研究では、小規模高品質コーパスに基づくベイズ的データ選別を通じて、目的特化対話に求められる会話スタイルをローカルLLMへ反映する手法「BASiS (Bayesian Style-based Selection)」を提案する。BASiSでは、まずLLMを用いて小規模高品質コーパスを分析し、各対話を、会話相手の状況や対話段階を表す会話状態、共感・質問・助言などの応答方針を表す応答戦略、および応答によって生じる状態遷移として構造化する。次に、抽出した会話構造から、状態間の遷移確率と各状態における応答戦略の観測尤度を持つベイズ的対話モデルを構築する。構築したモデルを用いて、大規模汎用コーパスに含まれる各対話データを目的の会話スタイルへの適合度に基づいてスコアリングし、学習に用いるデータを選別する。最後に、選別したデータから選好ペアを構築し、LoRAを適用したDirect Preference Optimization (DPO) によってローカルLLMを学習することで、小規模コーパスに含まれる会話スタイルをモデルに反映する。

BASiSの特徴は、小規模コーパスに含まれる会話スタイルを、個別の応答表現や手で作成した詳細なガイドラインとしてではなく、会話状態と応答戦略の確率的な遷移として表現する点にある。これにより、目的ごとの詳細な対話ガイドラインの手動記述を前提とせず、コーパスに暗黙的に含まれる対話の流れをデータ選別に利用できる。また、単一の応答戦略だけを正解とするのではなく、対話状態を確率分布として保持し、ベイズ更新によって候補応答を評価する。これにより、同一の文脈に対して複数の応答戦略が妥当となる会話の多様性を捉える。さらに、参照する小規模コーパスと選別対象となる大規模コーパスを

変更することで、感情支援、数学チュータリング、医療問診など、異なる目的特化対話に同じ手順を適用できる。選別したデータをLoRAベースのDPO学習に用いることで、ローカルLLMの一般的な対話能力を活用しながら、目的の会話スタイルを反映する。

本論文の構成は以下の通りである。第2章では、ガイドラインに基づく応答制御、対話状態に基づく応答戦略予測、およびLLMの学習データ選別に関する関連研究を紹介する。第3章では、提案手法BASISの全体構成と各モジュールの機能を述べる。第4章では、BASISの有効性を検証する実験、実験結果、および考察について述べる。最後に、第5章で本研究をまとめる。

2 関連研究

目的に応じた対話システムの振る舞いを実現する方法として、望ましい応答方針を自然言語のガイドラインとして与え、応答生成を制御する研究が行われている。Guptaらは、ガイドラインが適用される会話文脈と、応答に含めるべき内容を自然言語で記述するDialGuideを提案した[4]。DialGuideでは、ガイドラインの選択、ガイドラインに基づく応答生成、および生成応答がガイドラインを満たすかの検証を扱い、日常対話と安全性に関する対話データを用いた実験により、開発者のガイドラインに従った安全かつ対話性の高い応答を生成できることが示された。Wenらは、タスク指向対話における一連のガイドラインをマルコフ連鎖として表現するChained Priorを導入し、対話の進行に応じて方針を更新するGuidedTODを提案した[16]。GuidedTODは、Chained Priorによって応答候補を再ランキングすることで、既存手法と比較してガイドライン遵守性能を向上させ、行動予測の正解率を約20%改善した。これらの研究は、望ましい振る舞いを明示的なガイドラインとして表現し、そのガイドラインを応答選択や応答生成に反映することの有効性を示している。

人手で定めたガイドラインを直接用いるのではなく、ユーザの状態やそれまでの対話から、次取るべき応答戦略を予測する研究も行われている。Chengらは、ユーザの細かな感情表現と感情の原因を捉え、将来のユーザ反応を先読みしながら応答戦略を選択するMultiESCを提案した[2]。MultiESCでは、A*探索に着想を得た先読み評価によって、長期的な支援効果が高いと予測される戦略を選択し、実験では応答戦略の計画と応答生成の双方において既存手法を上回った。Dengらは、ユーザとシステムのどちらが会話を主導しているかを表す発話分類と評価指標を導入し、戦略予測、外部知識の選択、応答生成を組み合わせたKnowledge-enhanced Mixed-Initiative model (KEMI)を提案した[3]。KEMIは、メンタルヘルス対話から構築した知識グラフを利用して、対話の状況に応じた応答戦略と知識を選択し、内容保持とmixed-initiative性の双方に関する評価で既存手法を上回った。Wanらは、ユーザの細粒度な感情状態とシステムの応答戦略との関係を異種グラフとしてモデル化するEmoDynamixXを提案した[15]。EmoDynamixXは、戦略予測と応答生成を分離し、グラフ上の関係に基づいて次の応答戦略を予測する。二つの感情支援対話データセットを用いた実験では、既存手法より高い戦略予測性能を示すと同時に、特定の戦略への選好の偏りを低減し、戦略選択の過程を遡って確認できることが示された。

LLMを効率的に目的へ適応させるため、学習に用いるデータの量ではなく、データの品質や有効性を重視する研究も進められている。Zhouらは、慎重に選定した1,000件の指示応答データのみを用いてLLaMAを学習するLIMAを提案し、少量の高品質データであっても、モデルが望ましい応答形式や対話的な振る舞いを学習できることを示した[21]。人手評価では、LIMAの応答がGPT-4の応答と同等以上と判断された割合が43%となり、より大規模なアライメント用データを用いた複数のモデルに対しても高い性能を示した。Chenらは、強力なLLMによって各指示応答データの品質を評価し、低品質なデータを除外するAlpaGasusを提案した[1]。AlpaGasusは、Alpacaの52,000件から選別した9,000件のみで学習され、すべてのデータを用いたAlpacaを自動評価と人手評価の双方で上回るとともに、学習時間を大幅に短縮し

た. Liuらは, 指示データの複雑さ, 品質, 多様性を個別に評価し, これらを組み合わせてデータを選別するDEITAを提案した[8]. DEITAは, ベースラインの10分の1以下となる6,000件のSFTデータを用いながら, 当時の主要なオープンソースモデルと同等以上の性能を示した. Xiaらは, 少数の目的タスク例と各学習データとの勾配類似度から, 目的能力の獲得に影響を与えるデータを推定するLESSを提案した[17]. LESSでは, 選別元データの5%のみを用いた学習が, 複数の下流タスクにおいて全データを用いた学習を上回り得ることが示され, 目的に応じたデータ選別の有効性が確認された.

以上の研究は, 応答方針の制御, 応答戦略の予測, および学習データの効率的な選別において成果を示している. 一方で, 本研究が対象とする会話スタイルの選別という観点からは, 大きく三つの課題が残る. 第一に, DialGuideやGuidedTODのようなガイドラインに基づく手法では, 目的や領域ごとに望ましい対話方針を人手で記述する必要がある. 会話のトーン, 応答を行うタイミング, 複数ターンにわたる対話の進め方など, コーパス内に暗黙的に表れる特徴を網羅的なガイドラインとして明示することは難しく, 設計には高いコストを要する. 第二に, MultiESC, KEMI, EmoDynamiXなどの応答戦略予測手法は, ユーザ状態や将来の対話への影響を考慮して戦略を選択できる一方, 最終的には各ターンにおいて特定の戦略を選択し, その戦略に基づいて応答を生成する. 実際の対話では, 同一の文脈に対して複数の応答戦略がいずれも妥当となる場合があるため, 単一の予測結果だけでは, 目的コーパスに含まれる応答の多様性を十分に表現することが困難である. 第三に, LIMAは少量の高品質データによる学習の有効性を示し, AlpaGasusとDEITAは, 応答の品質, 複雑さ, 多様性などに基づいてデータを選別している. また, LESSは, 少数の目的タスク例に対する学習上の影響度に基づいてデータを選別する. しかし, 一般的な品質や目的タスクへの有効性が同程度の応答であっても, 応答を行うタイミングや, 応答によって生じる会話状態の遷移が異なれば, 目的コーパスの会話スタイルへの適合度は異なる. 会話履歴, 応答戦略, 状態遷移を選別基準に含めない場合, このような違いを十分に識別できず, 目的コーパスに特徴的な対話の流れを保持したデータを安定して選別することが困難である.

3 BASiS

3.1 コンセプト

本研究では, 小規模高品質コーパスに基づくベイズ的データ選別を通じて, 目的特化対話に求められる会話スタイルをローカル大規模言語モデル (LLM) へ反映する手法BASiS (Bayesian Style-based Selection) を提案する. BASiSの目的は, 小規模コーパスに暗黙的に表れる応答方針や対話の進め方を, ローカルLLMの学習に利用できる形へ変換することである. 小規模高品質コーパスをそのまま学習に用いるのではなく, そこから会話状態, 応答戦略, 状態遷移を抽出して確率的な対話モデルを構築し, 大規模汎用コーパスの選別基準として利用する.

BASiSにより, 大規模汎用コーパスに含まれる各対話データを, 目的コーパスに特徴的な会話スタイルへの適合度に基づいて評価できる. 目的や領域ごとの詳細な対話ガイドラインの手動記述を前提とせず, 小規模コーパスに含まれる対話の流れを学習データへ反映する. また, 会話状態を一つに決定せず確率分布として保持することで, 同一の文脈に対して複数の応答戦略が妥当となる会話の多様性を扱う. 最終的に, 選別したデータを用いてDPO学習を行い, 小規模コーパスに含まれる会話スタイルをローカルLLMへ反映する.




Fig. 1. BASiSの全体構成。上段では、小規模高品質コーパスから会話特徴を抽出し、ベイズ的対話モデルを構築する。下段では、構築したモデルによって大規模汎用コーパスの候補応答をスコアリングし、得られた選好データを用いたLoRA-DPOによりローカルLLMを適応させる。①-④は本文で説明する4つのモジュールに対応する。

3.2 BASiSの構成

BASiSの全体構成を図1に示す。BASiSは、**Dialogue Feature Analysis Module**、**Bayesian Dialogue Modeling Module**、**Style Compatibility Scoring Module**、**Preference Data Selection and DPO Adaptation Module**の4つのモジュールから構成される。

図1の上段Aは、小規模高品質コーパスから選別基準となるスタイルモデルを構築する*Style Model Induction*の流れを示す。はじめに、Dialogue Feature Analysis Module (図中の①)が、小規模コーパスの対話データから会話状態、応答戦略、状態遷移を会話特徴として抽出する。次に、Bayesian Dialogue Modeling Module (②)が、抽出された特徴の出現傾向を集計し、状態遷移確率と観測尤度からなるベイズ的対話モデルを構築する。

下段Bは、このモデルを用いて学習データを選び、LLMを適応させる*Data Selection & Adaptation*の流れを示す。Style Compatibility Scoring Module (③)には、上段で構築したベイズ的対話モデルと、大規模汎用コーパスからなる候補プールの対話データが入力される。本モジュールは各候補応答に0から1の適合度スコアを付与する。Preference Data Selection and DPO Adaptation Module (④)は、このスコアからchosen応答とrejected応答の選好ペアを構築し、LoRAを適用したDPOによってローカルLLMを学習する。したがって、小規模コーパスは会話スタイルを抽出する参照元、大規模コーパスは実際の学習データを選ぶ候補プールとして役割が分かれている。両コーパスを変更することで、異なる目的特化対話にも同一のパイプラインを適用できる。

Dialogue Feature Analysis Module (会話特徴分析モジュール)

Dialogue Feature Analysis Moduleは、図1の①に対応し、小規模高品質コーパスに含まれる各対話をLLMによって分析する。本モジュールは、目的コーパスに特徴的な会話の進め方を構造化するため、各ターンを会話状態、応答戦略、および状態遷移の三つの要素で表現する。

会話状態 s_t は、ターン t における対話相手の状況や対話の段階を表す。例えば、感情支援では感情を開示している段階や解決策を検討している段階、数学チュータリングでは学習者が推論を試みている段階や誤りを整理している段階、医療問診では症状を提示している段階や追加情報を確認している段階などが該当する。応答戦略を表す観測ラベル o_t は、その状態に対して応答者が取った方針を表し、共感、質問、情報

整理, ヒント, 情報提供, 助言などが含まれる. 状態遷移は, コーパス中で応答戦略 o_t が用いられたターンを介して, 会話状態 s_{t-1} から s_t へどのように変化したかを表す.

この処理を小規模コーパス全体へ適用することで, (s_{t-1}, o_t, s_t) からなる組の集合を得る. これにより, 表層的な語彙や個別の応答文だけではなく, どのような状態に対してどのような応答戦略が用いられ, その後どのような状態へ進みやすいかという会話の構造を抽出する. この構造は, コーパスに暗黙的に含まれる会話スタイルを, 後続のモジュールで利用可能な形式に変換したものである.

Bayesian Dialogue Modeling Module (ベイズ対話モデル構築モジュール)

Bayesian Dialogue Modeling Moduleは, Dialogue Feature Analysis Moduleで得られた会話特徴から, 目的コーパスの会話の流れを表すベイズの対話モデルを構築する. 会話状態の集合を $S = \{s_1, \dots, s_K\}$, 応答戦略に対応する観測ラベルの集合を $O = \{o_1, \dots, o_L\}$ とする.

ベイズ的対話モデルは, 状態遷移確率 $P(s_t | s_{t-1})$ と観測尤度 $P(o_t | s_t)$ から構成される. 状態遷移確率は, 目的コーパスにおいて, 会話状態 s_{t-1} から s_t へ移行する確率を表す. 目的コーパス内で頻繁に観測される対話の流れには高い確率が与えられ, ほとんど観測されない流れには低い確率が与えられる. 観測尤度は, 会話状態 s_t にあるときに, 応答戦略 o_t が観測される確率を表す.

これら二つの確率分布を組み合わせることで, 目的コーパスにおいて, どのような対話状態が生じやすく, 各状態でのどのような応答戦略が用いられやすいかを表現する. 構築したモデルは, 小規模コーパスに実際に含まれていた発話だけを記憶するものではなく, 状態と戦略の確率的な関係を表す. そのため, 小規模コーパスに含まれていない新たな候補応答に対しても, 同じモデルを用いて会話スタイルへの適合度を評価できる.

Style Compatibility Scoring Module (スタイル適合度スコアリングモジュール)

Style Compatibility Scoring Moduleは, ベイズ的対話モデルを用いて, 大規模汎用コーパスに含まれる候補応答 r_t を, 目的コーパスの会話スタイルへの適合度に基づいて評価する. 本モジュールの処理を図2に示す. 図中の①-⑤は, 事前状態の設定, 状態予測, 応答ラベルの付与, ベイズ更新, 適合度スコアの算出という以下の処理に対応する.

はじめに, 候補応答が提示される前の対話状態を, 一つの状態に固定するのではなく, 状態集合 S 上の確率分布として保持する (図2の①). 図の例では, ターン $t-1$ までの状態分布 $b_{t-1}(s)$ として, Emotion disclosureに0.30, Emotion processingに0.45, Considering solutionsに0.25を割り当てている. 次に, 状態遷移確率を用いて, ターン t における状態の予測分布を次式によって計算する (図中の②).

$$\hat{b}_t(s_t) = \sum_{s_{t-1} \in S} P(s_t | s_{t-1}) b_{t-1}(s_{t-1}). \quad (1)$$

図2の②に示す状態遷移図は, Disclosure, Processing, Solutionsという状態間の遷移と, 各遷移で観測される代表的な応答戦略の対応を模式的に示す. 式(1)では, これらの遷移の出現傾向を表す $P(s_t | s_{t-1})$ によって, 直前の分布 b_{t-1} を予測分布 $\hat{b}_t$ へ写像する.

続いて, Dialogue Feature Analysis Moduleと同じラベル体系を用いて, LLMが候補応答 r_t を観測ラベル o_t に分類する (図中の③). 図の例では, 候補応答“That sounds really difficult.”が*Empathy / validation*に分類される. この観測ラベルと観測尤度を用いて, 予測分布 $\hat{b}_t(s_t)$ をベイズ則によって更新する.

$$b_t(s_t) = \frac{P(o_t | s_t) \hat{b}_t(s_t)}{\sum_{s' \in S} P(o_t | s') \hat{b}_t(s')}. \quad (2)$$




Fig. 2. Style Compatibility Scoring Moduleにおける候補応答の評価処理の模式例．前ターンまでの状態分布を遷移モデルにより予測し、候補応答から得た観測ラベルを用いてベイズ更新を行う．青色の経路は予測分布、橙色の経路は観測ラベルが更新式のどの項へ入力されるかを示す．例では、更新後の分布における対象状態ProcessingとSolutionsの確率を合計し、Score = 0.88を得る．

ここで、 $b_t(s_t)$ は、それまでの観測を予測分布 $\hat{b}_t(s_t)$ に反映した上で、観測履歴 $o_{1:t}$ を条件とする事後確率 $P(s_t | o_{1:t})$ を表す．図2の④では、橙色の経路が観測ラベル o_t によって尤度 $P(o_t | s_t)$ を定める流れ、青色の経路が予測分布 $\hat{b}_t(s_t)$ を更新式へ入力する流れを示す．分母は全状態について正規化を行い、更新後の確率の総和を1にする．この例では、更新後の分布はDisclosureが0.12、Processingが0.66、Solutionsが0.22となる．

最後に、対象とする会話スタイルにおいて望ましいと定義された状態群を $S_{\text{target}} \subseteq S$ とし、候補応答 r_t の適合度スコアを、更新後の状態分布における S_{target} の確率の合計として定義する．

$$\text{Score}(r_t) = \sum_{s \in S_{\text{target}}} b_t(s). \quad (3)$$

適合度スコアは0から1までの値を取り、値が大きいほど、候補応答を観測した後の状態分布が、目的コーパスにおいて望ましい状態群と強く整合することを表す．図2の⑤では、 $S_{\text{target}} = \{\text{Processing}, \text{Solutions}\}$ とし、 $0.66 + 0.22 = 0.88$ を候補応答の適合度スコアとしている．一般には、感情支援における感情の整理や適切な解決策の検討、数学チューティングにおける学習者自身の推論の進展、医療問診における必要な症状情報の段階的な整理などを、対象領域に応じて S_{target} として設定できる．

本モジュールは、次の応答戦略の一つの正解として固定せず、対話状態を確率分布として保持したまま候補応答を評価する．候補応答ごとに一つの観測ラベルを付与する場合でも、異なる応答戦略が望ましい状態群において高い観測尤度を持つならば、それぞれに対応する候補応答が高い適合度スコアを得られる．したがって、同一の文脈に複数の妥当な応答戦略が存在する場合も、単一の戦略に限定せず評価できる．

Preference Data Selection and DPO Adaptation Module (選好データ選別・DPO適応学習モジュール)

Preference Data Selection and DPO Adaptation Moduleは、Style Compatibility Scoring Moduleが算出した適合度スコアに基づいて、大規模汎用コーパスから学習に用いる応答を選別する．各会話文脈に対して構成された候補応答のうち、目的の会話スタイルへの適合度が高い応答を*chosen*、低い応答を*rejected*として選び、選好ペアを構築する．

Table 1. 評価に用いたコーパスペアと各コーパスの役割

対話目的	小規模高品質コーパス	大規模汎用コーパス
感情支援	ESConv	DailyDialog
数学チュータリング	MathDial	WildChat-1M
医療問診	MediTOD	WildChat-1M

構築した選好ペアは、Direct Preference Optimization (DPO) [12]によるローカルLLMの学習に用いる。DPOは、chosen応答がrejected応答よりも選択されやすくなるようにモデルを直接最適化する。本研究では、モデル全体のパラメータを更新するのではなく、Low-Rank Adaptation (LoRA) [5]を適用し、追加された低ランクパラメータのみを更新する。これにより、ローカルLLMが持つ一般的な言語生成能力を活用しながら、選別されたデータに含まれる目的の会話スタイルを効率的に反映する。学習に用いるモデル、ハイパーパラメータ、および学習データ数については、第4章で述べる。

4 評価実験

4.1 実験目的

本実験の目的は二つである。第一の目的は、BASiSによって選別したデータを用いて学習したモデルが、小規模高品質コーパスに含まれる目的固有の会話スタイルを再現できるかを検証することである。このため、BASiSによる選別データで学習したモデルを、学習前のベースモデル、および目的コーパスの大まかな話題を表すキーワードで絞り込んだカテゴリから無作為に選別したデータで学習したモデルと比較する。これにより、BASiSを用いた学習によって目的の会話スタイルが強化されるか、また、その変化がDPO学習の有無だけでなく、粗い話題の一致を超えてBASiSが行うデータ選別と関係するかを検証する。

第二の目的は、BASiSの有効性が特定の目的特化対話やコーパスの組み合わせに限られず、異なる目的の対話でも確認できるかを検証することである。本実験では、感情支援、数学チュータリング、医療問診の三種類の目的特化対話を対象とし、それぞれ異なる小規模高品質コーパスと大規模汎用コーパスを組み合わせで評価する。本稿では、大規模言語モデルを評価者として用いるOracle評価により、各条件が目的コーパスに特徴的な会話スタイルをどの程度再現しているかを比較する。

4.2 実験方法

本実験では、表1に示す三種類のコーパスペアを用いた。各実験設定では、小規模高品質コーパスを目的の会話スタイルを抽出するための参照元として使用し、大規模汎用コーパスをBASiSによる選別対象の候補プールとして使用した。

感情支援対話の実験では、支援を求める話者と支援者の対話を収録したESConv[7]を小規模高品質コーパスとし、日常的な複数ターン対話からなるDailyDialog[6]を大規模汎用コーパスとした。数学チュータリング対話の実験では、教師とLLMが演じる学習者との一対一の数学対話を収録したMathDial[9]を小規模高品質コーパスとし、実環境におけるユーザとLLMの対話からなるWildChat-1M[20]を大規模汎用コーパスとした。医療問診対話の実験では、医療従事者が作成した医師と患者の問診対話を収録するMediTOD[14]を小規模高品質コーパスとし、MathDialの実験と同様にWildChat-1Mを大規模汎用コーパスとした。

各実験設定では、まず小規模高品質コーパスからベイズ的対話モデルを構築し、大規模汎用コーパスに含まれる候補応答をStyle Compatibility Scoring Moduleによって評価した。得られた適合度スコアに基づいて選好データを構築し、LoRAを適用したDPOによってローカルLLMを学習した。BASiSによる選別の効果を比

Table 2. 各実験条件におけるDPO学習と学習データの選別方法

条件	DPO学習	学習データの選別方法
Base	×	なし
BASiS	✓	適合度スコア
Random	✓	キーワードカテゴリ内で無作為

較するため、Random条件も構築した。Random条件では、小規模高品質コーパスの主要な話題を表す大まかなキーワードを用いて大規模汎用コーパスをカテゴリ単位で絞り込み、そのカテゴリ内から学習データを無作為に選別した。データ数と学習方法はBASiS条件と揃えた。各実験設定について100件の評価用プロンプトを用意し、学習前のベースモデル、BASiSによる選別データで学習したモデル、キーワードで絞り込んだカテゴリから無作為に選別したデータで学習したモデルから、それぞれ応答を生成した。三条件で同じ評価用プロンプトを用いることで、プロンプトの違いによる影響を抑えた対応のある比較とした。

Oracle評価では、LLMを評価者として用いて、各モデルの応答が目的コーパスに特徴的な会話スタイルをどの程度再現しているかを評価した。評価時にはモデル名を提示せず、三条件の応答の提示順をランダム化した。Oracle LLMにはGPT-5.4を使用し、出力の変動を抑えるためtemperatureを0に設定した。Oracle LLMには、評価用プロンプト、それまでの会話履歴、および評価対象の応答を入力し、表3に示す各評価軸について1から10点で採点させた。評価軸は、各目的特化対話の元コーパスで重視される性質と、関連研究の評価方法を参考に定義した。これにより、応答内容だけでなく、目的に応じた応答方針、応答のタイミング、および複数ターンにわたる対話の進め方を評価した。各評価軸について、Base、BASiS、Randomの三条件間の差をFriedman検定で検証した。有意差が認められた場合は、BASiSとBase、およびBASiSとRandomの対応比較に置換検定（permutation test）を用い、Holm法で多重比較を補正した。有意水準は $\alpha = .05$ とした。平均値の不確実性は、ブートストラップ95%信頼区間によって示した。

4.3 実験条件と評価方法

本実験では、BASiSによる学習の効果と、BASiSによるデータ選別そのものの効果を分けて検証するため、以下の二つの比較を行った。

BASiSによる学習効果の評価： BASiSによって選別したデータを用いた学習が、目的コーパスの会話スタイルの再現度を向上させるかを検証するため、学習を行っていないBase条件と、BASiSによる選別データで学習したBASiS条件を比較した。

データ選別の効果の評価： BASiS条件で確認された変化が、DPO学習を行ったこと自体や粗い話題の一致だけではなく、BASiSによるデータ選別に起因するかを検証するため、BASiS条件とRandom条件を比較した。Random条件では、小規模高品質コーパスの主要な話題を表す大まかなキーワードで大規模汎用コーパスをカテゴリ単位に絞り込み、そのカテゴリ内からBASiS条件と同数の学習データを無作為に選別した。学習方法とハイパーパラメータはBASiS条件と共通とした。

表2に、三つの実験条件を示す。Base条件はDPO学習を行っていない学習前のモデルである。BASiS条件は、適合度スコアに基づいて選別したデータを用いてDPO学習を行ったモデルである。Random条件は、キーワードで大まかに絞り込んだカテゴリ内から無作為に選別したデータを用いてDPO学習を行ったモデルである。また、すべての実験設定で、同一のローカルLLMであるQwen3.5-72Bを使用した。Base条件には学習前のモデルを使用し、BASiS条件とRandom条件にはLoRAを適用したDPO学習を行った。各実験設定に

Table 3. 各実験におけるOracle評価軸（1-10点；すべて高いほど望ましい）

評価軸	評価内容
コーパスペア：ESConv × DailyDialog	
Style Strength	ESConvに特徴的な共感的支援スタイルの明確さ
ESConv Tone Similarity	温かく受容的で非断定的な語調のESConv類似度
Supporter Role Consistency	支援者の役割を保ち、説教・自己開示・逸脱を避ける度合い
Non-directive Support Style	意思を尊重し、断定や押し付けを避ける度合い
Strategy/Stage Alignment	応答戦略とその時点の会話段階との適合
Premature Advice Avoidance	感情・状況を理解してから助言へ移る適切さ
Naturalness	文脈に合った自然な日本語会話としての成立度
コーパスペア：MathDial × WildChat-1M	
Equitable Tutoring	学習者が自ら考え、説明し、解法を探索する余地
Learner Reasoning Diagnosis	学習者の推論の正誤・不足・混乱の把握
Mistake Location and Targeting	推論の誤りや未完了箇所の正確な特定
Guidance Quality	質問・ヒント・説明・例の正確さと有用性
Feedback Actionability	次に考え、計算し、確認すべき行動の明確さ
Answer Revealing Calibration	解答を示す量・時機と理解状態・会話段階の適合
Teacher Move-Stage Alignment	教師の応答戦略と会話段階の適合
コーパスペア：MediToD × WildChat-1M	
Response Relevance	直前までの症状・背景に即した質問・応答の関連性
Overall Quality	関連性・明瞭さ・自然さ・情報収集への有用性
Premature Assessment Avoidance	情報不足時に診断・治療方針を急がない度合い
Appropriate Uncertainty	不確実性と追加確認の必要性を適切に示す度合い
Understandability	専門用語を抑えた明確で理解しやすい質問・説明
Unsafe Medical Advice Avoidance	有害となり得る不適切な医学的助言を避ける度合い
Unsupported Diagnosis Avoidance	根拠不足時に特定の疾患・原因の断定を避ける度合い

において、BASIS条件とRandom条件の学習データ数および選好データの形式を揃え、両条件の主な違いが、ベイジック対話モデルによる会話スタイル適合度に基づく選別と、粗い話題カテゴリ内での無作為選別となるようにした。DPOの学習率は 5×10^{-6} 、 $\beta = 0.1$ とした。LoRAはランク $r = 8$ 、 $\alpha = 16$ 、dropoutを0.05とし、学習エポック数を1とした。これらの学習設定は三種類のコーパスペアで共通とし、実験設定間で学習条件が変化しないようにした。

表3に、各実験設定で用いる七つのOracle評価軸をまとめる。

ESConvにおけるOracle評価軸：ESConvとDailyDialogを用いた実験では、評価軸によって感情支援対話のスタイルと会話進行を捉える。具体的には、ESConvに特徴的な共感的支援スタイルの強さと語調に加え、支援者としての役割、非指示的な応答方針、応答戦略と会話段階の適合、助言を行うタイミング、および日本語対話としての自然さを評価する[3, 7, 10, 19]。

MathDialにおけるOracle評価軸：MathDialとWildChat-1Mを用いた実験では、数学的な答えの正しさだけでなく、学習者自身の推論を促し、現在の理解状態に応じて適切な教育的支援を行えているかを評価する[9]。具体的には、学習者に思考の余地を残すこと、推論を正確に診断すること、誤りの箇所を特定すること、および質問、ヒント、説明、解答提示を会話段階に応じて使い分けることを扱う。




Fig. 3. ESConvとDailyDialogを用いた実験におけるOracle評価結果．棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧はBASISとBase，またはBASISとRandomのHolm補正後の対応比較を表す（* $p < .05$ ，** $p < .01$ ，*** $p < .001$ ）．

MediTODにおけるOracle評価軸： MediTODとWildChat-1Mを用いた実験では，病歴聴取の適切さ，応答品質，および医学的安全性を評価する[14]．具体的には，直前までの症状や背景に即した応答，医療対話としての総合的な品質，情報不足時に診断や治療方針を急がないこと，不確実性の扱い，患者にとっての理解しやすさ，および根拠の乏しい診断や危険な医学的助言の回避を扱う．なお，表中のUnsafe Medical Advice AvoidanceおよびUnsupported Diagnosis Avoidanceについては，危険な助言や根拠のない診断を行う度合いではなく，それらを適切に回避できている度合いとして採点する．したがって，他の評価軸と同様に，得点が高いほど望ましい応答であることを表す．

4.4 実験結果

本章では，ESConvとDailyDialog，MathDialとWildChat-1M，MediTODとWildChat-1Mの三つのコーパスペアにおけるOracle評価の結果を報告する．図3-5は，各評価軸について，Base，BASIS，Randomの平均値とブートストラップ95%信頼区間を示す．括弧上のアスタリスクは，Holm補正後の対応あり置換検定によるBASISと各比較条件との差を表す．*は $p < .05$ ，**は $p < .01$ ，***は $p < .001$ を示す．

実験条件1：ESConv × DailyDialog

図3に，感情支援対話に関する七つの評価軸の結果を示す．BASISは，すべての評価軸でBaseおよびRandomを上回る平均値を示した．Style Strengthでは，Baseが8.26，BASISが8.65，Randomが8.21であり，BASISはBaseおよびRandomの双方に対して有意に高かった（いずれも $p < .001$ ）．ESConv Tone Similarityでも，Baseが8.21，BASISが8.52，Randomが8.13となり，BASISは両条件を有意に上回った（いずれも $p < .001$ ）．Oracle評価では，感情支援スタイルの全体的な強さだけでなく，共感的・受容的・非断定的な語調にも改善が認められた．

Supporter Role Consistencyでは，Baseが8.34，BASISが8.60，Randomが8.41であり，BASISはBaseに対して $p < .01$ ，Randomに対して $p < .05$ で有意に高かった．Non-directive Support Styleでは，Baseが7.84，BASISが8.34，Randomが7.99となり，BASISはBaseに対して $p < .01$ ，Randomに対して $p < .05$ で有意に高かった．この結果は，単一応答の語調に加えて，複数ターンにわたり支




Fig. 4. MathDialとWildChat-1Mを用いた実験におけるOracle評価結果．棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧はBASiSとBase，またはBASiSとRandomのHolm補正後の対応比較を表す (** * $p < .001$) ．

援者の立場を保ち，相手に結論を押しつけずに会話を進める傾向も強まったことを示唆する．Strategy/Stage Alignmentでは，Baseが7.84，BASiSが8.32，Randomが7.98であり，BASiSはBaseを有意に上回った ($p < .01$) が，Randomとの差は有意ではなかった．Premature Advice Avoidanceでは，Baseが8.57，BASiSが9.44，Randomが8.92であり，BASiSはBaseに対して $p < .001$ ，Randomに対して $p < .05$ で有意に高かった．Baseとの差は0.87ポイントであり，七つの評価軸の中で最も大きかった．これらの結果から，応答戦略を会話段階に合わせ，感情や状況を十分に理解してから助言へ移る傾向が強まったと考えられる．Naturalnessでは，Baseが8.35，BASiSが8.53，Randomが8.17であり，BASiSはRandomを有意に上回った ($p < .01$) が，Baseとの差は有意ではなかった．したがって，BASiSによるスタイル適応は，日本語対話としての自然さを損なわずに実現されたと考えられる．

実験条件2：MathDial × WildChat-1M

図4に，数学チュータリング対話に関する七つの評価軸の結果を示す．BASiSは，七つすべての評価軸においてBaseおよびRandomを上回り，すべての対応比較で有意差が認められた (すべて $p < .001$) ．Equitable Tutoringでは，Baseが6.77，BASiSが7.75，Randomが6.00であり，BASiSはBaseを0.98ポイント，Randomを1.75ポイント上回った．Oracle評価では，教師側から直ちに答えを提示せず，学習者自身が考え，説明し，解法を試す余地を残す応答がBASiS条件で増えたと判断された．Learner Reasoning Diagnosisでは，Baseが7.38，BASiSが8.70，Randomが6.97であり，BASiSはBaseを1.32ポイント，Randomを1.73ポイント上回った．Mistake Location and Targetingでも，Baseが7.53，BASiSが8.85，Randomが7.27となり，BASiSはBaseを1.32ポイント，Randomを1.58ポイント上回った．Oracle評価では，学習者の推論の正誤を捉えるだけでなく，誤りや未完了箇所を具体的に特定する応答にも改善が認められた．Guidance Qualityでは，Baseが6.88，BASiSが8.02，Randomが6.57であり，Feedback Actionabilityでは，Baseが7.01，BASiSが8.03，Randomが6.18であった．特にFeedback ActionabilityにおけるBASiSとRandomの差は1.85ポイントであり，七つの評価軸の中で最も大きかった．Oracle評価では，学習者が次に考え，計算し，確認すべき内容を明確にする教育的な応答が，BASiS条件で増えたと判断された．Answer Revealing Calibrationでは，Baseが7.88，BASiSが8.86，Randomが7.50であり，Teacher Move-Stage Alignmentで




Fig. 5. MediTODとWildChat-1Mを用いた実験におけるOracle評価結果．棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧はBASiSとBase，またはBASiSとRandomのHolm補正後の対応比較を表す（* $p < .05$ ，** $p < .01$ ，*** $p < .001$ ）．

は、Baseが7.44、BASiSが8.62、Randomが7.06であった．これらの結果から、答えを示す量とタイミング、および質問、焦点化、説明といった教師の応答戦略を、学習者の状態や会話段階に合わせる傾向が強まったと考えられる．

実験条件3：MediTOD × WildChat-1M

図5に、医療問診対話に関する七つの評価軸の結果を示す．BASiSは七つすべての評価軸において最も高い平均スコアを示したが、統計的な差の現れ方は評価軸によって異なった．Response Relevanceでは、Baseが4.46、BASiSが5.09、Randomが4.91であり、Overall Qualityでは、それぞれ5.16、5.69、5.46であった．BASiSはいずれもBaseを有意に上回った（ともに $p < .01$ ）が、Randomとの差は有意ではなかった．粗い話題カテゴリから選別したRandom条件でも応答の関連性と総合品質が一定程度確保されており、この二軸ではBASiSとの差を結論づけられない．Premature Assessment Avoidanceでは、Baseが8.43、BASiSが8.90、Randomが8.63であり、BASiSが最も高い平均値を示したが、Holm補正後の対応比較では有意差が認められなかった．Appropriate Uncertaintyでは、Baseが7.84、BASiSが8.26、Randomが7.92であり、BASiSはBaseおよびRandomの双方を有意に上回った（いずれも $p < .01$ ）．したがって、Oracle評価から統計的に確認されたのは、確定できない事項について不確実性や追加確認の必要性を示す傾向の強まりである．Understandabilityでは、Baseが8.56、BASiSが8.77、Randomが8.55であり、BASiSは両条件を有意に上回った（いずれも $p < .05$ ）．Unsafe Medical Advice Avoidanceでは、Baseが9.52、BASiSが9.71、Randomが9.36であり、BASiSはBaseに対して $p < .001$ 、Randomに対して $p < .05$ で有意に高かった．Unsupported Diagnosis Avoidanceでは、Baseが9.62、BASiSが9.82、Randomが9.61であり、BASiSは両条件を有意に上回った（いずれも $p < .05$ ）．これらの結果は、BASiSが患者に理解しやすい表現を保ちながら、根拠の乏しい医療助言や診断を避ける応答方針を強めたことを示唆する．

4.5 考察

本実験では、感情支援、数学チュータリング、医療問診という性質の異なる三種類の目的特化対話を対象としてBASiSを評価した。Oracle評価では、BASiSが三つの実験設定に含まれる合計21の評価軸すべてにおいて、BaseおよびRandomよりも高い平均スコアを示した。一方、有意差の現れ方は領域と評価軸によって異なり、感情支援と数学チュータリングでは広範な改善が確認されたのに対し、医療問診では応答の関連性・総合品質と安全性に異なる傾向が見られた。以下では、それぞれの結果が示す意味について考察する。

考察1：感情支援対話における会話スタイルの再現

ESConvとDailyDialogを用いた実験では、BASiSが七つの評価軸すべてで最高の平均値を示した。特に大きな改善が見られたのは、相手の感情や状況を理解してから助言へ移れているかを表すPremature Advice Avoidanceと、断定や押し付けを避けて対話を進められているかを表すNon-directive Support Styleであった。Style StrengthとESConv Tone SimilarityもBaseおよびRandomを有意に上回っており、ESConvに特徴的な共感表現や柔らかな語調と、助言を行うタイミングの双方に変化が表れたと考えられる。また、支援者の役割を維持できているかを表すSupporter Role Consistencyは両比較条件を、応答戦略が会話段階に適しているかを表すStrategy/Stage AlignmentはBaseを有意に上回った。したがって、BASiSの効果は単一ターンの表層表現に限定されず、会話の進行に応じた応答方針にも及ぶ可能性がある。NaturalnessはRandomを有意に上回り、Baseとの差は有意ではなかったことから、スタイル適応によって日本語対話としての自然さが損なわれたとは認められない。これらは、会話スタイルを語彙だけでなく、対話状態と応答戦略の関係として表現するBASiSの設計と整合する。

考察2：数学チュータリングにおける教育的対話方針の再現

MathDialとWildChat-1Mを用いた実験では、七つすべての評価軸において、BASiSがBaseおよびRandomを有意に上回った。数学チュータリングでは、正しい答えを生成するだけでなく、学習者の推論の正誤や不足を把握し（Learner Reasoning Diagnosis）、誤りや未完了箇所を特定すること（Mistake Location and Targeting）が求められる。さらに、学習者の理解状態に合わせて解答を示す量と時機を調整し（Answer Revealing Calibration）、質問・ヒント・説明などの応答戦略を会話段階に合わせる必要がある（Teacher Move-Stage Alignment）。これらの軸を含むすべての軸で改善したことは、目的コーパスに含まれる教育的な対話の進め方がBASiS条件に反映された可能性を示す。特に、学習者が次に考え、計算し、確認すべき行動の明確さを表すFeedback Actionabilityにおいて、BASiSとRandomの差が最も大きかった。これは、話題を大まかに合わせたカテゴリ内から無作為に選別したデータでは、応答として自然であっても、学習者の次の行動へつながる教育的な構造が十分に含まれないことを示唆している。一方、BASiSは、MathDialから抽出した会話状態と応答戦略の遷移に適合するデータを選別することで、学習者の次の推論や計算へつながる応答をモデルに反映できたと考えられる。また、Randomは七つすべての軸でBaseを下回った。ただし、本研究ではBaseとRandomの差を直接検定していないため、ランダムなDPO学習によって教育的な応答能力が低下したとは結論づけられない。一方、BASiSがBaseとRandomの双方を上回ったことは、DPO学習の有無だけでなく、学習データの選び方が重要であることを示している。

考察3：医療問診における応答品質と安全性

MediToDとWildChat-1Mを用いた実験では、BASiSが七つの評価軸すべてで最高の平均値を示した。不確実性と追加確認の必要性を適切に示しているかを表すAppropriate Uncertainty、患者にとって理解しやすいかを表すUnderstandability、危険な医学的助言を避けられているかを表すUnsafe Medical Advice Avoidance、および根拠のない診断を避けられているかを表すUnsupported Diagnosis Avoidanceでは、BASiSがBaseおよ

びRandomを有意に上回った。この結果は、患者に理解しやすい表現を保ちながら、十分な情報が得られていない段階で断定的な判断や助言を行わない応答方針が強まったことを示唆する。一方、直前までの症状や背景に即した応答かを表すResponse Relevanceと、関連性・明瞭さ・自然さ・情報収集への有用性をまとめたOverall Qualityでは、BASiSがBaseを有意に上回ったが、Randomとの差は有意ではなかった。Randomは粗いキーワードカテゴリから選別されているため、話題の一致によって関連性と総合品質が一定程度確保された可能性がある。また、情報不足時に診断や治療方針を急いでいないかを表すPremature Assessment Avoidanceでも、BASiSの平均値は最も高かったが、有意差は認められなかった。したがって、BASiSの優位性は医療問診のすべての側面で同じ強さを持つとは結論づけられない。

考察4：応答内容ではなく対話の進め方を選別する効果

三つの実験設定を横断すると、BASiSの改善は一般的な応答品質に加え、応答のタイミングや対話段階との整合性に関係する評価軸でも確認された。感情支援では、感情や状況を理解してから助言へ移る適切さ（Premature Advice Avoidance）が両比較条件を上回り、会話段階に応じた応答戦略（Strategy/Stage Alignment）はBaseを上回った。数学チューティングでは、解答を示す量・時機と理解状態の適合（Answer Revealing Calibration）、および教師の応答戦略と会話段階の適合（Teacher Move-Stage Alignment）が両比較条件を上回った。医療問診では、不確実性と追加確認の必要性の適切な表明（Appropriate Uncertainty）、および情報不足時における診断の回避（Unsupported Diagnosis Avoidance）が両比較条件を上回った。これらの評価軸は、いずれも応答文単体の内容だけでは決まらず、それまでの会話履歴と現在の対話段階を考慮する必要がある。さらに、感情支援におけるNaturalness、医療問診におけるResponse Relevance, Overall Quality, Understandabilityでも、少なくとも一方の比較条件に対する改善が確認された。したがって、BASiSは目的固有の応答方針を強める一方で、一般的な自然さや理解しやすさを維持または改善できる可能性がある。この結果は、式(3)に示したように、候補応答を単一ターンの一般的な品質ではなく、状態遷移と観測ラベルに基づく事後確率によって評価するBASiSの設計と整合する。小規模高品質コーパスから抽出した会話状態と応答戦略の遷移を選別基準とすることで、目的コーパスに特徴的な「どの段階で、どのように応答するか」を選別に反映できた可能性がある。

考察5：BASiSによるデータ選別の寄与

BASiSは三つの実験設定のすべての評価軸でRandomよりも高い平均スコアを示した。BASiS条件とRandom条件では、使用するベースモデル、学習データ数、DPOの学習方法、およびLoRAの設定を共通とした。Random条件は大規模汎用コーパス全体から無制約に抽出したものではなく、小規模コーパスの話題を表す大まかなキーワードで絞り込んだカテゴリ内から無作為に選別している。したがって、両条件の比較は、粗い話題の一致を超えて、会話状態・応答戦略・状態遷移に基づく適合度を選別基準に用いることの追加的な寄与を検証するものとなる。特にMathDialでは、RandomがBaseをすべての評価軸で下回った一方、BASiSはBaseをすべての評価軸で上回った。この対照的な結果は、学習データの量や学習手法だけでなく、話題が大まかに一致するデータの中から、どのデータを選ぶかによって目的固有の会話スタイルへの適応結果が変わり得ることを示唆する。したがって、大規模汎用コーパスを目的特化対話へ利用する際には、話題による絞り込みだけでなく、目的コーパスの対話進行と整合するデータを選ぶことが重要だと考えられる。

考察6：三つの目的特化対話への適用可能性

BASiSは、参照元となる小規模高品質コーパスと選別対象となる大規模汎用コーパスを変更することで、感情支援、数学チューティング、医療問診の三領域へ同一のパイプラインを適用した。その結果、すべての領域でBASiSが全評価軸の最高平均値を示したことは、本手法がESConvの感情支援スタイルだけに特化したものではなく、異なる目的コーパスに含まれる会話スタイルを抽出し、学習データの選別に利用できる

可能性を示している．一方，感情支援と医療問診にはRandomとの差が有意でない評価軸も存在したことから，BASiSの効果がすべての領域およびすべての会話スタイル要素に同じ強さで現れるわけではない．目的コーパスごとに，どの状態を望ましい状態群 S_{target} として定義するか，どの応答戦略を観測ラベルとして抽出するかによって，強く反映される会話スタイルの側面が変化すると考えられる．したがって，BASiSのパイプライン自体は領域を横断して共通化できる一方，状態・戦略の定義と望ましい状態群の設定については，各目的特化対話の性質を適切に分析し，定義できるように強化することが今後の課題である．

5 結論

本研究では，小規模高品質コーパスに基づくベイズ的データ選別によって，目的特化対話に求められる会話スタイルをローカル大規模言語モデル（LLM）へ反映する手法BASiS（Bayesian Style-based Selection）を提案した．BASiSは，小規模コーパスから会話状態・応答戦略・状態遷移を抽出し，ベイズ的対話モデルとして表現する．このモデルを用いて大規模汎用コーパスの候補応答を評価し，得られた選好データによってローカルLLMを学習する．この仕組みにより，目的ごとの詳細な対話ガイドラインを人手で記述することなく，小規模コーパスに含まれる応答方針と複数ターンにわたる対話の進め方を，学習データの選別基準として利用できる．また，会話状態を確率分布として扱うことで，同じ文脈に対して複数の応答戦略が妥当となる会話の多様性を保ちながら，目的に適したデータを選別できる．

異なる性質を持つ三種類の目的特化対話を対象とした比較実験では，BASiSがすべての評価軸で最も高い平均評価を示した．実験結果から，BASiSは，共感的な応答と助言のタイミング，学習者の理解状態に応じた教育的支援，および理解しやすさを保ちながら不確実な状況で断定を避ける応答方針を，それぞれの目的に応じてモデルへ反映できる可能性が示された．さらに，大まかなキーワードで絞り込んだカテゴリから無作為に選別したデータを用いる条件との比較から，粗い話題の一致だけでなく，目的の会話スタイルに基づいて学習データを選別することの重要性が示唆された．

今後は，異なるモデルへの適用可能性を評価するとともに，目的に応じた会話状態・応答戦略・望ましい状態群の設計方法を検討する．これらを通じて，カウンセリング，教育，医療をはじめとする多様な目的特化対話への応用を目指す．

References

- [1] Lichang Chen, Shiyang Li, Jun Yan, Hai Wang, Kalpa Gunaratna, Vikas Yadav, Zheng Tang, Vijay Srinivasan, Tianyi Zhou, Heng Huang, and Hongxia Jin. 2024. AlpacaSUS: Training a Better Alpaca with Fewer Data. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=FdVXgSJhVz>
- [2] Yi Cheng, Wenge Liu, Wenjie Li, Jiashuo Wang, Ruihui Zhao, Bang Liu, Xiaodan Liang, and Yefeng Zheng. 2022. Improving Multi-turn Emotional Support Dialogue Generation with Lookahead Strategy Planning. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Abu Dhabi, United Arab Emirates, 3014–3026. doi:10.18653/v1/2022.emnlp-main.195
- [3] Yang Deng, Wenxuan Zhang, Yifei Yuan, and Wai Lam. 2023. Knowledge-enhanced Mixed-initiative Dialogue System for Emotional Support Conversations. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, Toronto, Canada, 4079–4095. doi:10.18653/v1/2023.acl-long.225
- [4] Prakhar Gupta, Yang Liu, Di Jin, Behnam Hedayatnia, Spandana Gella, Sijia Liu, Patrick Lange, Julia Hirschberg, and Dilek Hakkani-Tur. 2023. DialGuide: Aligning Dialogue Model Behavior with Developer Guidelines. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 14031–14047. doi:10.18653/v1/2023.findings-emnlp.935
- [5] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2022. LoRA: Low-Rank Adaptation of Large Language Models. The Tenth International Conference on Learning Representations (ICLR 2022). <https://openreview.net/forum?id=nZeVKeeFYf9>
- [6] Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. DailyDialog: A Manually Labelled Multi-turn Dialogue Dataset. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Asian Federation of Natural Language Processing, Taipei, Taiwan, 986–995. <https://aclanthology.org/I17-1099/>

- [7] Siyang Liu, Chujie Zheng, Orianna Demasi, Sahand Sabour, Yu Li, Zhou Yu, Yong Jiang, and Minlie Huang. 2021. Towards Emotional Support Dialog Systems. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, Online, 3469–3483. doi:10.18653/v1/2021.acl-long.269
- [8] Wei Liu, Weihao Zeng, Keqing He, Yong Jiang, and Junxian He. 2024. What Makes Good Data for Alignment? A Comprehensive Study of Automatic Data Selection in Instruction Tuning. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=BTKAeLqLMw>
- [9] Jakub Macina, Nico Daheim, Sankalan Pal Chowdhury, Tanmay Sinha, Manu Kapur, Iryna Gurevych, and Mrinmaya Sachan. 2023. MathDial: A Dialogue Tutoring Dataset with Rich Pedagogical Properties Grounded in Math Reasoning Problems. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 5602–5621. doi:10.18653/v1/2023.findings-emnlp.372
- [10] Remi Mir, Bjarke Felbo, Nick Obradovich, and Iyad Rahwan. 2019. Evaluating Style Transfer for Text. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Association for Computational Linguistics, Minneapolis, Minnesota, 495–504. doi:10.18653/v1/N19-1049
- [11] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. 2022. Training Language Models to Follow Instructions with Human Feedback. In *Advances in Neural Information Processing Systems*, Vol. 35. Curran Associates, Inc., Red Hook, NY, USA, 27730–27744.
- [12] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. 2023. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 53728–53741. doi:10.52202/075280-2338
- [13] Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. 2019. Towards Empathetic Open-domain Conversation Models: A New Benchmark and Dataset. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Florence, Italy, 5370–5381. doi:10.18653/v1/P19-1534
- [14] Vishal Vivek Saley, Goonjan Saha, Rocktim Jyoti Das, Dinesh Raghu, and Mausam. 2024. MediTOD: An English Dialogue Dataset for Medical History Taking with Comprehensive Annotations. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Miami, Florida, USA, 16843–16877. doi:10.18653/v1/2024.emnlp-main.936
- [15] Chenwei Wan, Matthieu Labeau, and Chloé Clavel. 2025. EmoDynamix: Emotional Support Dialogue Strategy Prediction by Modelling MiXed Emotions and Discourse Dynamics. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Association for Computational Linguistics, Albuquerque, New Mexico, 1678–1695. doi:10.18653/v1/2025.naacl-long.81
- [16] Xiangyu Wen, Jianyuan Zhong, Zhijian Xu, and Qiang Xu. 2025. Guideline Compliance in Task-Oriented Dialogue: The Chained Prior Approach. In *Findings of the Association for Computational Linguistics: NAACL 2025*. Association for Computational Linguistics, Albuquerque, New Mexico, 6765–6791. doi:10.18653/v1/2025.findings-naacl.377
- [17] Mengzhou Xia, Sadhika Malladi, Suchin Gururangan, Sanjeev Arora, and Danqi Chen. 2024. LESS: Selecting Influential Data for Targeted Instruction Tuning. In *Proceedings of the 41st International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 235)*. PMLR, Vienna, Austria, 54104–54132. <https://proceedings.mlr.press/v235/xia24c.html>
- [18] Bolin Zhang, Jiahao Wang, Qianlong Du, Jiajun Zhang, Zhiying Tu, and Dianhui Chu. 2025. A Survey on Data Selection for LLM Instruction Tuning. *Journal of Artificial Intelligence Research* 83, Article 32 (2025), 14 pages. doi:10.1613/jair.1.17625
- [19] Saizheng Zhang, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela, and Jason Weston. 2018. Personalizing Dialogue Agents: I have a dog, do you have pets too?. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, Melbourne, Australia, 2204–2213. doi:10.18653/v1/P18-1205
- [20] Wenting Zhao, Xiang Ren, Jack Hessel, Claire Cardie, Yejin Choi, and Yuntian Deng. 2024. WildChat: 1M ChatGPT Interaction Logs in the Wild. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=Bl8u7ZRLbM>
- [21] Chunting Zhou, Pengfei Liu, Puxin Xu, Srinu Iyer, Jiao Sun, Yuning Mao, Xuezhe Ma, Avia Efrat, Ping Yu, Lili Yu, Susan Zhang, Gargi Ghosh, Mike Lewis, Luke Zettlemoyer, and Omer Levy. 2023. LIMA: Less Is More for Alignment. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 55006–55021. doi:10.52202/075280-2400