

BASiS:

ベイズ的データ選別による目的特化対話システムの会話行動適応

ANONYMOUS AUTHOR(S)

本論文では、小規模高品質な対話コーパスを単なる発話例の集合として利用するのではなく、そこに暗黙に含まれる対話の進め方を、会話状態の遷移と各状態における応答戦略の確率分布としてモデル化し、このモデルを大規模汎用コーパスから学習データを選ぶ基準へ転用する手法BASiS (Bayesian Style-based Selection) を提案する。本研究は、相手の状態や対話局面に応じて対話を進行させる必要がある場面に着目する。こうした対話の質を支えるのは、個々の発話内容だけではなく、相手の状況をどのように捉え、どのタイミングでどの対話方策を用いるかという、インタラクションにおける手続的知識である。しかし、このような知識は小規模な高品質対話コーパスに暗黙的に含まれている一方、そのままでは大規模なLLM学習に十分なデータ量を確保できない。BASiSは、この知識を会話状態・応答戦略・状態遷移の確率モデルとして抽出し、大規模汎用コーパスの学習データ選別基準へ変換することで、少量の高品質対話に含まれる知識を大規模学習へスケールさせる。BASiSでは、小規模コーパスから会話状態、応答戦略、状態遷移を抽出し、それらをベイズ的対話モデルとして表現する。次に、大規模コーパスに含まれる対話を、目的の会話スタイルへの適合度に基づいてスコアリングし、学習データを選別する。さらに、選別したデータから選好ペアを構築し、Direct Preference Optimization (DPO) を用いてLLMを学習する。これにより、詳細な対話ガイドラインを人手で設計する負担を軽減しながら、一般的な品質や話題の類似性だけでは捉えにくい応答のタイミングや複数ターンにわたる対話の進行を、データ選別に反映できる。また、単一の応答戦略に固定するのではなく、会話状態を確率分布として保持することで、同一の文脈に対する複数の妥当な応答戦略を維持できる。感情支援、数学チュータリング、医療問診を対象として、学習前のベースモデル、BASiSによる選別データで学習したモデル、および目的コーパスのカテゴリ内から無作為に選別したデータで学習したモデルを比較することで、BASiSを評価した。その結果、BASiSは三領域の全21評価軸で最高の平均値を示し、感情支援と数学チュータリングでは広範な有意改善が確認された。

CCS Concepts: • **Computing methodologies** → **Natural language generation**; **Discourse, dialogue and pragmatics**; Learning from implicit feedback; • **Human-centered computing** → **Natural language interfaces**.

Additional Key Words and Phrases: 目的特化対話システム, 会話スタイル, データ選別, ベイズ的対話モデリング, 選好最適化, 感情支援対話, 大規模言語モデル

ACM Reference Format:

Anonymous Author(s). 2026. BASiS:ベイズ的データ選別による目的特化対話システムの会話行動適応. In *Proceedings of 32nd Annual ACM Conference on Intelligent User Interfaces (IUI '27)*. ACM, New York, NY, USA, 17 pages.

1 はじめに

Instruction tuningやRLHFの発展により、近年の大規模言語モデル (LLM) は、指示に従って正確な応答を生成し、多様な話題について自然で一貫した複数ターン対話を行えるようになった[10]。一方、感情支援、数学チュータリング、医療問診などの目的特化対話では、正しい情報を提示するだけでなく、相手の状態や対話の段階に応じて適切な応答方針を選ぶ必要がある[6, 12]。例えば、相手の感情を受け止めてから助言へ移ること、学習者自身の推論を促すこと、必要な症状を適切な順序で聞き出すことが求められる。このよ

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM.

Manuscript submitted to ACM

Manuscript submitted to ACM

うな会話スタイルは、目的に沿って構築された小規模高品質コーパスに表れているが、そのままLLMの学習に用いるにはデータ量が限られる。これに対し、大規模汎用コーパスはデータ量と多様性に優れるものの、目的の会話スタイルに適合する対話を十分に含むとは限らない。そこで、小規模高品質コーパスに含まれる対話の進め方を、LLMの実際の応答生成へ反映する方法が必要となる。

目的特化対話に適した応答を生成するため、既存研究では複数のアプローチが検討されている。ガイドラインに基づく応答制御では、望ましい対話方針をあらかじめ明示的に定義し、その方針に従うように応答生成を制御する。WenらのGuidedTODは、タスク指向対話の流れを確率的に表現し、対話の進行に応じてガイドラインに基づく方針を更新しながら応答候補を再ランキングすることで、既存手法よりも高いガイドライン遵守性能を示した[16]。また、対話履歴から次の対話行動や応答戦略を予測する研究も行われている。Ganeshらは、授業対話において教師が次を取るtalk moveを予測し[2]、WanらのEmoDynamixは、ユーザの複数の感情状態と応答戦略の関係を異種グラフとしてモデル化した[15]。Rudolphらは、カウンセリング対話から得た遷移行列を次対話行動予測の正則化に用いた[13]。さらに、LLMの学習に用いるデータの選別に関する研究では、少量であっても高品質なデータを適切に選ぶことで、効率的にモデルの振る舞いを調整できることが示されている[18, 21]。

しかし、これらの既存研究には二つの課題がある。第一に、ガイドラインに基づく応答制御では、目的や領域ごとに望ましい対話方針を手で記述する必要がある。会話のトーン、応答のタイミング、複数ターンにわたる対話の進め方など、コーパスに暗黙的に表れる会話スタイルを網羅的なルールとして明示することは難しい。第二に、対話行動や応答戦略に関する既存研究は、対話の流れをモデル化して次の行動や戦略を予測することを主な対象としており、その予測に基づく自然言語応答の生成や、生成応答の品質評価までは扱っていない。そのため、コーパスから学習した対話構造を、実際の応答生成へどのように反映するかは十分に検討されていない。

これらの課題を解決するため、本研究では、小規模高品質コーパスに基づくベイズ的データ選別を通じて、目的特化対話に求められる会話スタイルをローカルLLMへ反映する手法「BASiS (Bayesian Style-based Selection)」を提案する。BASiSでは、まずLLMを用いて小規模高品質コーパスを分析し、各対話を、会話相手の状況や対話段階を表す会話状態、共感・質問・助言などの応答方針を表す応答戦略、および応答によって生じる状態遷移として構造化する。次に、抽出した会話構造から、状態間の遷移確率と各状態における応答戦略の観測尤度を持つベイズ的対話モデルを構築する。構築したモデルを用いて、大規模汎用コーパスに含まれる各対話データを目的の会話スタイルへの適合度に基づいてスコアリングし、学習に用いるデータを選別する。最後に、選別したデータから選好ペアを構築し、LoRAを適用したDirect Preference Optimization (DPO) によってローカルLLMを学習することで、小規模コーパスに含まれる会話スタイルをモデルに反映する。

BASiSの特徴は、小規模コーパスに含まれる会話スタイルを、個別の応答表現や人手で作成した詳細なガイドラインとしてではなく、会話状態と応答戦略の確率的な遷移として表現する点にある。これにより、目的ごとの詳細な対話ガイドラインの手動記述を前提とせず、コーパスに暗黙的に含まれる対話の流れをデータ選別に利用できる。また、対話状態を確率分布として保持し、候補応答から得た観測によってベイズ更新することで、現在の会話履歴と応答後の状態遷移を選別基準に反映する。さらに、参照する小規模コーパスと選別対象となる大規模コーパスを変更することで、感情支援、数学チューティング、医療問診など、異なる目的特化対話に同じ手順を適用できる。選別したデータをLoRAベースのDPO学習に用いることで、ローカルLLMの一般的な対話能力を活用しながら、目的の会話スタイルを反映する。

本論文の構成は以下の通りである。第2章では、ガイドラインに基づく応答制御、対話履歴に基づく対話行動・応答戦略予測、およびLLMの学習データ選別に関する関連研究を紹介する。第3章では、提案手

法BASISの学習パイプラインと各モジュールの機能を述べる。第4章では、BASISの有効性を検証する実験、実験結果、および考察について述べる。最後に、第5章で本研究をまとめる。

2 関連研究

目的に応じた対話システムの振る舞いを実現する方法として、望ましい応答方針を自然言語のガイドラインとして与え、応答生成を制御する研究が行われている。Guptaらは、ガイドラインが適用される会話文脈と、応答に含めるべき内容を自然言語で記述するDialGuideを提案した[3]。DialGuideでは、ガイドラインの選択、ガイドラインに基づく応答生成、および生成応答がガイドラインを満たすかの検証を扱い、日常対話と安全性に関する対話データを用いた実験により、開発者のガイドラインに従った安全かつ対話性の高い応答を生成できることが示された。Wenらは、タスク指向対話における一連のガイドラインをマルコフ連鎖として表現するChained Priorを導入し、対話の進行に応じて方針を更新するGuidedTODを提案した[16]。GuidedTODは、Chained Priorによって応答候補を再ランキングすることで、既存手法と比較してガイドライン遵守性能を向上させ、行動予測の正解率を約20%改善した。これらの研究は、望ましい振る舞いを明示的なガイドラインとして表現し、そのガイドラインを応答選択や応答生成に反映することの有効性を示している。

人手で定めたガイドラインを直接用いるのではなく、それまでの対話から次の対話行動や応答戦略を予測する研究も行われている。Ganeshらは、授業対話の履歴とそれまでのtalk moveから、教師が次を取るtalk moveを予測するFuture Talk Move Predictionを提案した[2]。教師の対話行動を多クラス分類としてモデル化した結果、提案モデルは複数のベースラインを大きく上回り、人間による予測との比較でも共通する傾向を示した。Wanらは、ユーザの細粒度な感情状態とシステムの応答戦略との談話的な関係を異種グラフとしてモデル化するEmoDynamiXを提案した[15]。二つの感情支援対話データセットを用いた実験では、既存手法より高いF1値と小さい戦略選好の偏りを示し、予測過程を遡って確認できる解釈可能性も示した。Rudolphらは、カウンセリング対話から得られる対話行為の遷移行列をKL正則化項として用い、予測分布を実際の対話フローへ近づける次対話行為予測手法を提案した[13]。この手法は、複数のエンコードにおいてmacro-F1を相対9-42%改善するとともに、予測結果と対話フローとの整合性を向上させた。

LLMを効率的に目的へ適応させるため、学習データの量だけでなく、品質や目的との適合性を重視する研究も進められている。LIMAは、少量の高品質な指示応答データでも、望ましい応答形式や対話的な振る舞いを学習できることを示した[21]。AlpaGasusとDEITAは、品質、複雑さ、多様性などに基づいてデータを選別し、より少ない学習データで高い性能を実現した[1, 7]。LESSは、目的タスク例への学習上の影響度に基づく選別の有効性を示した[17]。これらの結果は、データ量を増やすだけでなく、目的に適した高品質なデータを選ぶことが、効率的なモデル適応に重要であることを示している。

以上の研究は、応答方針の制御、対話行動・応答戦略の予測、および学習データの効率的な選別において成果を示している。一方で、目的特化対話の会話スタイルを実際の応答生成へ反映するうえでは、二つの課題が残る。第一に、DialGuideやGuidedTODのようなガイドラインに基づく手法では、目的や領域が変わるたびに、望ましい対話方針を人手で設計する必要がある。会話のトーン、応答を行うタイミング、相手の状態に応じた方針の切り替え、複数ターンにわたる対話の進め方など、コーパス内に暗黙的に表れる特徴を網羅的なガイドラインとして記述することは難しい。そのため、ガイドラインの設計には高いコストを要する。さらに、記述されていない特徴は制御へ反映されにくく、制御の範囲と品質がガイドラインの完全性に左右される。第二に、対話行動や応答戦略をモデル化する既存研究は、予測を主な評価対象としており、その結果を用いた自然言語応答の生成までは十分に検証していない。Ganeshらの出力は教師が次を取るtalk moveのラベルであり、そのtalk moveに沿った教師応答の生成は扱っていない。Wanら

のEmoDynamixは、予測した応答戦略を外部の生成モデルへ渡せる構成を示しているが、研究上の評価対象は戦略予測のF1値、戦略選好の偏り、および解釈可能性であり、生成された感情支援応答の品質は評価していない。Rudolphらも、次対話行為の予測性能と対話フローへの整合性を評価しており、応答生成と統合したend-to-end評価は未検証としている。

3 BASiS

3.1 コンセプト

本研究では、小規模高品質コーパスに基づくベイズ的データ選別を通じて、目的特化対話に求められる会話スタイルをローカル大規模言語モデル（LLM）へ反映する手法BASiS（Bayesian Style-based Selection）を提案する。BASiSの目的は、小規模コーパスに暗黙的に表れる応答方針や対話の進め方を、ローカルLLMの学習に利用できる形へ変換することである。小規模高品質コーパスをそのまま学習に用いるのではなく、そこから会話状態、応答戦略、状態遷移を抽出して確率的な対話モデルを構築し、大規模汎用コーパスの選別基準として利用する。BASiSにより、大規模汎用コーパスに含まれる各対話データを、目的コーパスに特徴的な会話スタイルへの適合度に基づいて評価できる。目的や領域ごとの詳細な対話ガイドラインの手動記述を前提とせず、小規模コーパスに含まれる対話の流れを学習データへ反映する。また、会話状態一つに決定せず確率分布として保持することで、同一の文脈に対して複数の応答戦略が妥当となる会話の多様性を扱う。最終的に、選別したデータを用いてDPO学習を行い、小規模コーパスに含まれる会話スタイルをローカルLLMへ反映する。

3.2 BASiSの学習パイプライン

BASiSの学習パイプラインを図1に示す。本パイプラインは、**Dialogue Feature Analysis Module**、**Bayesian Dialogue Modeling Module**、**Style Compatibility Scoring Module**、**Preference Data Selection and DPO Adaptation Module**の4つのモジュールで構成されており、スタイルモデルの誘導から学習データの選別、DPOによるモデル適応までを行う。

図1の上段Aは、小規模高品質コーパスから選別基準となるスタイルモデルを構築する*Style Model Induction*の流れを示す。はじめに、Dialogue Feature Analysis Module（図中の①）が、小規模コーパスの対話データから会話状態、応答戦略、状態遷移を会話特徴として抽出する。次に、Bayesian Dialogue Modeling Module（②）が、抽出された特徴の出現傾向を集計し、状態遷移確率と観測尤度からなるベイズ的対話モデルを構築する。下段Bは、このモデルを用いて学習データを選び、LLMを適応させる*Data Selection & Adaptation*の流れを示す。Style Compatibility Scoring Module（③）には、上段で構築したベイズ的対話モデルと、大規模汎用コーパスからなる候補プールの対話データが入力される。本モジュールは各候補応答に0から1の適合度スコアを付与する。Preference Data Selection and DPO Adaptation Module（④）は、このスコアからchosen応答とrejected応答の選好ペアを構築し、LoRAを適用したDPOによってローカルLLMを学習する。したがって、小規模コーパスは会話スタイルを抽出する参照元、大規模コーパスは実際の学習データを選ぶ候補プールとして役割が分かれている。両コーパスを変更することで、異なる目的特化対話にも同一のパイプラインを適用できる。

Dialogue Feature Analysis Module（会話特徴分析モジュール）

Dialogue Feature Analysis Moduleは、図1の①に対応し、LLMを用いて小規模高品質コーパスを分析し、目的固有の会話の進め方を表すラベル体系を生成する。本研究ではGPT-5.4-proを使用し、temperatureはAPIの既定値、reasoning effortはhighとした。LLMにはコーパスの会話本文と既存アノテーションを提示する。




Fig. 1. BASiSの学習パイプライン。上段では、小規模高品質コーパスから会話特徴を抽出し、ベイズ的対話モデルを構築する。下段では、構築したモデルによって大規模汎用コーパスの候補応答をスコアリングし、得られた選好データを用いたLoRA-DPOによりローカルLLMを適応させる。①-④は本文で説明する4つのモジュールに対応する。

プロンプトでは、4-7個の潜在的な会話状態、各状態で観測される応答戦略、望ましい状態群と目的から外れる状態群、初期状態確率、状態遷移確率、および観測確率を生成するよう指示する。会話状態は対話相手の状況や対話段階、応答戦略は応答者が取る観測可能な方針を表すため、両者を同義のラベルにしないよう制約する。つまり、ラベル集合を手で固定するのでも、LLMに無制約で生成させるのでもなく、ラベル数・役割・出力形式を手で制約したラベル体系誘導 (ontology induction) として実施する。例えば、本実験で使用したESConvからは、挨拶や短い安否確認を通じて相談者が安心して話せる雰囲気を作る状態のopening_rapportと、相談者の感情を受け止めて承認し、孤立感や心理的負担を和らげる状態のempathic_supportが生成された。応答戦略としては、状況や悩みを詳しく理解するために出来事や背景を文脈に沿って尋ねるexplore_questionと、発言内容や感情を言い換えて認め、共感と受容を示すreflect_validateが生成された。

Bayesian Dialogue Modeling Module (ベイズ対話モデル構築モジュール)

Bayesian Dialogue Modeling Moduleは、Dialogue Feature Analysis Moduleが出力した会話状態、応答戦略、状態遷移を用いて、目的コーパスの会話の流れを表すベイズ的対話モデルを構築する。会話状態の集合を $S = \{s_1, \dots, s_K\}$ 、応答戦略に対応する観測ラベルの集合を $O = \{o_1, \dots, o_L\}$ とする。ベイズ的対話モデルは、初期状態確率 $P(s_1)$ 、状態遷移確率 $P(s_t | s_{t-1})$ と観測尤度 $P(o_t | s_t)$ から構成される。状態遷移確率は、目的コーパスから推定した、会話状態 s_{t-1} から s_t へ移行する相対的な傾向を表す。観測尤度は、会話状態 s_t にあるときに、応答戦略 o_t が観測される確率を表す。これらの確率は、LLMが小規模コーパス全体の傾向として推定した値を正規化したものである。確率分布を組み合わせることで、どのような対話状態が生じやすく、各状態でどのような応答戦略が用いられやすいかを表現する。構築したモデルは、小規模コーパス中の発言を記憶するのではなく、状態と戦略の確率的な関係を表すため、コーパスに含まれていない候補応答にも適用できる。

Style Compatibility Scoring Module (スタイル適合度スコアリングモジュール)

Style Compatibility Scoring Moduleは、ベイズ的対話モデルを用いて、大規模汎用コーパスに含まれる候補応答 r_t を、目的コーパスの会話スタイルへの適合度に基づいて評価する。本モジュールの処理を図2に示




Fig. 2. Style Compatibility Scoring Moduleにおける候補応答の評価処理の模式例。前ターンまでの状態分布を遷移モデルにより予測し、候補応答から得た観測ラベルを用いてベイズ更新を行う。青色の経路は予測分布、橙色の経路は観測ラベルが更新式のどの項へ入力されるかを示す。例では、更新後の分布における対象状態ProcessingとSolutionsの確率を合計し、Score = 0.88を得る。

す。図中の①-⑤は、事前状態の設定、状態予測、応答ラベルの付与、ベイズ更新、適合度スコアの算出という以下の処理に対応する。

はじめに、候補応答が提示される前の対話状態を、一つの状態に固定するのではなく、状態集合 S 上の確率分布として保持する（図2の①）。図の例では、ターン $t-1$ までの状態分布 $b_{t-1}(s)$ として、Emotion disclosureに0.30, Emotion processingに0.45, Considering solutionsに0.25を割り当てている。次に、状態遷移確率を用いて、ターン t における状態の予測分布を次式によって計算する（図中の②）。

$$\hat{b}_t(s_t) = \sum_{s_{t-1} \in S} P(s_t | s_{t-1}) b_{t-1}(s_{t-1}). \quad (1)$$

図2の②に示す状態遷移図は、Disclosure, Processing, Solutionsという状態間の遷移と、各遷移で観測される代表的な応答戦略の対応を模式的に示す。式(1)では、これらの遷移の出現傾向を表す $P(s_t | s_{t-1})$ によって、直前の分布 b_{t-1} を予測分布 $\hat{b}_t$ へ写像する。

続いて、固定済みのラベル体系を用いて、GPT-5.4が候補応答 r_t を観測ラベル o_t に分類する（図中の③）。temperatureはAPIの既定値、reasoning effortはhighとした。プロンプトには会話履歴、候補応答、許可された応答戦略ラベルとその説明を提示し、新しいラベルや状態名を生成せず、最も近い観測ラベルを必ず一つ選ぶよう指示する。出力は、観測ラベル、0-1の分類確信度、および簡潔な根拠を含むJSON objectとする。ここで分類確信度はラベル付けの付随情報であり、式(3)の適合度スコアとは異なる。図の例では、候補応答“That sounds really difficult.”がEmpathy/validationに分類される。この観測ラベルと観測尤度を用いて、予測分布 $\hat{b}_t(s_t)$ をベイズ則によって更新する。潜在状態をLLMが直接付与するのではなく、状態分布と状態遷移はこのベイズ更新によって推定される。

$$b_t(s_t) = \frac{P(o_t | s_t) \hat{b}_t(s_t)}{\sum_{s' \in S} P(o_t | s') \hat{b}_t(s')}. \quad (2)$$

ここで、 $b_t(s_t)$ は、それまでの観測を予測分布 $\hat{b}_t(s_t)$ に反映した上で、観測履歴 $o_{1:t}$ を条件とする事後確率 $P(s_t | o_{1:t})$ を表す。図2の④では、橙色の経路が観測ラベル o_t によって尤度 $P(o_t | s_t)$ を定める流れ、青色の経路が予測分布 $\hat{b}_t(s_t)$ を更新式へ入力する流れを示す。分母は全状態について正規化を行い、更新後の確

率の総和を1にする．この例では，更新後の分布はDisclosureが0.12，Processingが0.66，Solutionsが0.22となる．

最後に，対象とする会話スタイルにおいて望ましいと定義された状態群を $S_{\text{target}} \subseteq S$ とし，候補応答 r_t の適合度スコアを，更新後の状態分布における S_{target} の確率の合計として定義する．

$$\text{Score}(r_t) = \sum_{s \in S_{\text{target}}} b_t(s). \quad (3)$$

適合度スコアは0から1までの値を取り，値が大きいほど，候補応答を観測した後の状態分布が，目的コーパスにおいて望ましい状態群と強く整合することを表す．図2の⑥では， $S_{\text{target}} = \{\text{Processing}, \text{Solutions}\}$ とし， $0.66 + 0.22 = 0.88$ を候補応答の適合度スコアとしている．一般には，感情支援における感情の整理や適切な解決策の検討，数学チュータリングにおける学習者自身の推論の進展，医療問診における必要な症状情報の段階的な整理などを，対象領域に応じて S_{target} として設定できる．

本モジュールは，次の応答戦略の一つの正解として固定せず，対話状態を確率分布として保持したまま候補応答を評価する．候補応答ごとに一つの観測ラベルを付与する場合でも，異なる応答戦略が望ましい状態群において高い観測尤度を持つならば，それぞれに対応する候補応答が高い適合度スコアを得られる．したがって，同一の文脈に複数の妥当な応答戦略が存在する場合も，単一の戦略に限定せず評価できる．

Preference Data Selection and DPO Adaptation Module（選好データ選別・DPO適応学習モジュール）

Preference Data Selection and DPO Adaptation Moduleは，Style Compatibility Scoring Moduleが算出した適合度スコアに基づいて，大規模汎用コーパスから学習に用いる応答を選別する．各会話文脈に対して構成された候補応答のうち，目的の会話スタイルへの適合度が高い応答を*chosen*，低い応答を*rejected*として選び，選好ペアを構築する．構築した選好ペアは，Direct Preference Optimization（DPO）[11]によるローカルLLMの学習に用いる．DPOは，*chosen*応答が*rejected*応答よりも選択されやすくなるようにモデルを直接最適化する．本研究では，モデル全体のパラメータを更新するのではなく，Low-Rank Adaptation（LoRA）[4]を適用し，追加された低ランクパラメータのみを更新する．これにより，ローカルLLMが持つ一般的な言語生成能力を活用しながら，選別されたデータに含まれる目的の会話スタイルを効率的に反映する．

4 評価実験

4.1 実験目的

本実験の目的は二つである．第一の目的は，BASiSによって選別したデータを用いて学習したモデルが，小規模高品質コーパスに含まれる目的固有の会話スタイルを再現できるかを検証することである．このため，BASiSによる選別データで学習したモデルを，学習前のベースモデル，および目的コーパスの大まかな話題を表すキーワードで絞り込んだカテゴリから無作為に選別したデータで学習したモデルと比較する．これにより，BASiSを用いた学習によって目的の会話スタイルが強化されるか，また，その変化がDPO学習の有無だけでなく，粗い話題の一致を超えてBASiSが行うデータ選別と関係するかを検証する．第二の目的は，BASiSの有効性が特定の目的特化対話やコーパスの組み合わせに限られず，異なる目的の対話でも確認できるかを検証することである．本実験では，感情支援，数学チュータリング，医療問診の三種類の目的特化対話を対象とし，それぞれ異なる小規模高品質コーパスと大規模汎用コーパスを組み合わせで評価する．人間の評価者が目的固有の応答方針を望ましいと判断するかを人手評価によって検証するとともに，100件の対話例とLLMを用いたOracle評価によって，傾向の広がりや学習条件ごとの差を確認する．

Table 1. 評価に用いたコーパスペアと各コーパスの役割

対話目的	小規模高品質コーパス	大規模汎用コーパス
感情支援	ESConv	DailyDialog
数学チュータリング	MathDial	WildChat-1M
医療問診	Medi TOD	WildChat-1M

4.2 実験方法

本実験では、表1に示す三種類のコーパスペアを用いた。各実験設定では、小規模高品質コーパスを目的の会話スタイルを抽出するための参照元として使用し、大規模汎用コーパスをBASiSによる選別対象の候補プールとして使用した。感情支援対話の実験では、支援を求める話者と支援者の対話を収録したESConv[6]を小規模高品質コーパスとし、日常的な複数ターン対話からなるDailyDialog[5]を大規模汎用コーパスとした。数学チュータリング対話の実験では、教師とLLMが演じる学習者との一対一の数学対話を収録したMathDial[8]を小規模高品質コーパスとし、実環境におけるユーザとLLMの対話からなるWildChat-1M[20]を大規模汎用コーパスとした。医療問診対話の実験では、医療従事者が作成した医師と患者の問診対話を収録するMedi TOD[14]を小規模高品質コーパスとし、MathDialの実験と同様にWildChat-1Mを大規模汎用コーパスとした。

各実験設定のBASiS条件では、まず小規模高品質コーパスからベイズ的対話モデルを構築し、大規模汎用コーパスに含まれる候補応答をStyle Compatibility Scoring Moduleによって評価した。得られた適合度スコアに基づいて選好データを構築し、LoRAを適用したDPOによってローカルLLMを学習した。比較条件として、小規模高品質な目的コーパスのみで学習するTarget-only条件と、粗い話題カテゴリ内から学習データを無作為に選別するRandom条件を構築した。Random条件では、小規模高品質コーパスの主要な話題を表す大まかなキーワードを用いて大規模汎用コーパスをカテゴリ単位で絞り込み、そのカテゴリ内からBASiS条件と同数のデータを選別した。

人手評価は、研究室メンバー9名を対象に実施した。実験参加者が回答するための負担を抑えるため、各領域の評価用対話を10件に絞り、Base, BASiS, Randomの三条件を比較した。各対話について三つの応答をA-Cとしてモデル名を伏せて提示し、同じモデルが常に同じ記号にならないよう、応答と記号の対応を入れ替えた。評価者は、表4の各質問について、それぞれの応答がどの程度当てはまるかを1（全く当てはまらない）から7（非常によく当てはまる）までの7段階で評価した。さらに、各対話で目的に最も適した応答を一つ選択し、差を付けにくい場合は「ほぼ同じ」、評価できない場合は「判断できない」を選べるようにした。ESConvとMathDialでは9名全員の回答を用い、Medi TODでは未完了回答者2名を除いた7名の完全な回答を分析した。また、軸ごとに各参加者の10件の平均値を算出し、参加者を分析単位とした。三条件の差をFriedman検定で検証してKendallのWを効果量として求め、有意差が認められた軸では、三組すべての対応あり置換検定にHolm補正を適用した。平均値の95%信頼区間は、参加者単位のブートストラップを2,000回行って算出した。最終選択は同一参加者による反復回答であるため、件数と割合を記述統計として報告する。

Oracle評価では、各実験設定について100件の評価用対話を用意し、Base, Target-only, BASiS, Randomの各モデルから応答を生成した。四条件で同じ評価用対話を用いることで、対話の違いによる影響を抑えた対応のある比較とした。LLMを評価者として応答を比較し、評価時にはモデル名を提示せず、四条件の提示順をランダム化した。Oracle LLMにはGPT-5.4を使用し、temperatureを0に設定した。それまでの会話履歴

Table 2. 各実験条件におけるDPO学習と学習データ

条件	DPO学習	学習データ
Base	×	なし
Target-only	✓	小規模目的コーパスのみ
BASiS	✓	適合度スコアによる選別データ
Random	✓	キーワードカテゴリ内で無作為

と評価対象の応答に加え、表3の各評価軸について、定義、高得点・低得点となる条件、および共通の採点基準を提示した。採点基準は、1-2点を明確に不適切または文脈を無視した応答、3-4点を評価軸への適合が弱い応答、5-6点を最低限満たす応答、7-8点を十分に満たす良い応答、9-10点を改善点が少ない非常に良い応答とし、10点はほぼ理想的な応答に限定した。モデル名や応答の長さだけで判断しないよう指示し、軸別の1-10の整数値、総合値、および1-2文の根拠を出力させた。Oracle評価の各軸について四条件間の差をFriedman検定で検証し、有意な場合は六組すべての対応あり置換検定に軸内Holm補正を適用した。有意水準は $\alpha = .05$ とし、平均値にはブートストラップ95%信頼区間を示した。

4.3 実験条件と評価方法

本実験では、小規模目的コーパスを直接学習するだけで十分か、BASiSによる学習が有効か、およびデータ選別そのものに効果があるかを分けて検証するため、以下の三つの比較を行った。

目的コーパスのみを用いた学習の評価：小規模高品質コーパスのみを直接学習することで、目的の会話スタイルを十分に反映できるかを確認するため、Base条件とTarget-only条件を比較した。また、Target-only条件とBASiS条件の比較により、小規模コーパスを分析・モデル化して大規模汎用コーパスの選別へ利用することの追加的な効果を検証した。

BASiSによる学習効果の評価：BASiSによって選別したデータを用いた学習が、目的コーパスの会話スタイルの再現度を向上させるかを検証するため、学習を行っていないBase条件と、BASiSによる選別データで学習したBASiS条件を比較した。

データ選別の効果の評価：BASiS条件で確認された変化が、DPO学習を行ったこと自体や粗い話題の一致だけではなく、BASiSによるデータ選別に起因するかを検証するため、BASiS条件とRandom条件を比較した。Random条件では、小規模高品質コーパスの主要な話題を表す大まかなキーワードで大規模汎用コーパスをカテゴリ単位に絞り込み、そのカテゴリ内からBASiS条件と同数の学習データを無作為に選別した。学習方法とハイパーパラメータはBASiS条件と共通とした。

表2に、四つの実験条件を示す。Base条件はDPO学習を行っていない学習前のモデルである。Target-only条件は、小規模高品質な目的コーパスのみを用いてDPO学習を行ったモデルである。BASiS条件は、適合度スコアに基づいて大規模汎用コーパスから選別したデータを用いる。Random条件は、キーワードで大まかに絞り込んだカテゴリ内から無作為に選別したデータを用いる。また、すべての実験設定で、同一のローカルLLMであるQwen3.5-72Bを使用した。Base条件には学習前のモデルを使用し、Target-only、BASiS、Random条件にはLoRAを適用したDPO学習を行った。各実験設定において、BASiS条件とRandom条件の学習データ数および選好データの形式を揃え、両条件の主な違いが、ベイズ的対話モデルによる会話スタイル適合度に基づく選別と、粗い話題カテゴリ内での無作為選別となるようにした。DPOの学習率は 5×10^{-6} 、 $\beta = 0.1$ とした。LoRAはランク $r = 8$ 、 $\alpha = 16$ 、dropoutを0.05とし、学習

Table 3. 各実験におけるOracle評価軸（1-10点；すべて高いほど望ましい）

評価軸	評価内容
コーパスペア：ESConv × DailyDialog	
Style Strength	ESConvに特徴的な共感的支援スタイルの明確さ
ESConv Tone Similarity	温かく受容的で非断定的な語調のESConv類似度
Supporter Role Consistency	支援者の役割を保ち、説教・自己開示・逸脱を避ける度合い
Non-directive Support Style	意思を尊重し、断定や押し付けを避ける度合い
Strategy/Stage Alignment	応答戦略とその時点の会話段階との適合
Premature Advice Avoidance	感情・状況を理解してから助言へ移る適切さ
Naturalness	文脈に合った自然な会話としての成立度
コーパスペア：MathDial × WildChat-1M	
Equitable Tutoring	学習者が自ら考え、説明し、解法を探索する余地
Learner Reasoning Diagnosis	学習者の推論の正誤・不足・混乱の把握
Mistake Location and Targeting	推論の誤りや未完了箇所の正確な特定
Guidance Quality	質問・ヒント・説明・例の正確さと有用性
Feedback Actionability	次に考え、計算し、確認すべき行動の明確さ
Answer Revealing Calibration	解答を示す量・時機と理解状態・会話段階の適合
Teacher Move-Stage Alignment	教師の応答戦略と会話段階の適合
コーパスペア：Medi TOD × WildChat-1M	
Response Relevance	直前までの症状・背景に即した質問・応答の関連性
Overall Quality	関連性・明瞭さ・自然さ・情報収集への有用性
Premature Assessment Avoidance	情報不足時に診断・治療方針を急がない度合い
Appropriate Uncertainty	不確実性と追加確認の必要性を適切に示す度合い
Understandability	専門用語を抑えた明確で理解しやすい質問・説明
Unsafe Medical Advice Avoidance	有害となり得る不適切な医学的助言を避ける度合い
Unsupported Diagnosis Avoidance	根拠不足時に特定の疾患・原因の断定を避ける度合い

エピソード数を1とした。これらの学習設定は三種類のコーパスペアと三つのDPO学習条件で共通とし、実験設定間で学習条件が変化しないようにした。

表3に、各実験設定で用いる七つのOracle評価軸をまとめる。

ESConvにおけるOracle評価軸：ESConvとDailyDialogを用いた実験では、評価軸によって感情支援対話のスタイルと会話進行を捉える。具体的には、ESConvに特徴的な共感的支援スタイルの強さと語調に加え、支援者としての役割、非指示的な応答方針、応答戦略と会話段階の適合、助言を行うタイミング、および日本語対話としての自然さを評価する[6, 9, 19]。

MathDialにおけるOracle評価軸：MathDialとWildChat-1Mを用いた実験では、数学的な答えの正しさだけでなく、学習者自身の推論を促し、現在の理解状態に応じて適切な教育的支援を行えているかを評価する[8]。具体的には、学習者に思考の余地を残すこと、推論を正確に診断すること、誤りの箇所を特定すること、および質問、ヒント、説明、解答提示を会話段階に応じて使い分けることを扱う。

Medi TODにおけるOracle評価軸：Medi TODとWildChat-1Mを用いた実験では、病歴聴取の適切さ、応答品質、および医学的安全性を評価する[14]。具体的には、直前までの症状や背景に即した応答、医療対話としての総合的な品質、情報不足時に診断や治療方針を急がないこと、不確実性の扱い、患者にとっての理解しやすさ、および根拠の乏しい診断や危険な医学的助言の回避を扱う。なお、表中のUnsafe Medical Advice AvoidanceおよびUnsupported Diagnosis Avoidanceについては、危険な助言や根拠のない診断を行う

Table 4. 各実験における人手評価項目（7段階；1＝全く当てはまらない，7＝非常によく当てはまる）

項目	質問文
コーパスペア：ESConv × DailyDialog	
Q1	相談者を支える応答として，全体的に良い。
Q2	相談者の気持ちを受け止め，やさしく話している。
Q3	これまでの会話に合った，支える立場の話し方を続けている。
Q4	相手の話を理解・整理しようとし，指示や結論をすぐに押しつけていない。
Q5	この会話の段階に対して，助言や提案を出すタイミングが適切である。
Q6	これまでの話の内容によく合っている。
Q7	会話として自然で読みやすい。
最終選択	気持ちを受け止め，安心して話を続けられる支援応答として最も適切なものを選ぶ。
コーパスペア：MathDial × WildChat-1M	
Q1	学習者が自分で考え，説明し，解き方を試せる余地を残している。
Q2	学習者の考えが正しいか，どこが誤り・不十分かを正確に捉えている。
Q3	次に見直すべき箇所や考えるべき点を，具体的に絞っている。
Q4	質問，ヒント，説明が正確で，学習者の現在の理解に合っている。
Q5	学習者が次に何を考え，計算し，確かめればよいか分かる。
Q6	答えや解き方を示す量とタイミングが，会話の進み具合に合っている。
Q7	質問，ヒント，説明，理解確認の使い分けが，会話の段階に合っている。
最終選択	学習者の考えを捉え，自力で次に進めるよう支える個別指導応答として最も適切なものを選ぶ。
コーパスペア：MediToD × WildChat-1M	
Q1	すでに分かっている内容を不必要に聞き直さず，新しい必要情報を集めている。
Q2	情報がまだ足りない段階では，診断や対応を急いでいない。
Q3	分かっていることを断定せず，確かめる必要があることを適切に扱っている。
Q4	情報が十分でないのに，薬・治療・受診方法を強く決めつけて指示していない。
Q5	十分な根拠がないのに，病名や症状の原因を決めつけていない。
最終選択	必要な情報を集め，断定を避けて安全に進める医療者応答として最も適切なものを選ぶ。

度合いではなく，それらを適切に回避できている度合いとして採点する．したがって，他の評価軸と同様に，得点が高いほど望ましい応答であることを表す．

人手評価項目：人手評価では，目的固有の会話スタイルを，人間の評価者が理解しやすい質問文によって評価した．各質問は，提示された応答についてどの程度当てはまるかを7段階リッカート尺度で評価する形式とした．すべての質問項目について，1を「全く当てはまらない」，7を「非常によく当てはまる」とする．評価者には三条件のモデル名や学習方法を知らせず，応答内容のみに基づいて評価を求めた．

最終選択の選択肢は，三領域で共通して「応答A」「応答B」「応答C」「ほぼ同じ」「判断できない」とした．

4.4 実験結果

本章では，実験条件ごとの人手評価とOracle評価の結果を示す．

実験条件1：ESConv × DailyDialog

図3に実験条件1における人手評価の結果を示す．BASiSは七軸すべてで最高平均値を示し，助言のタイミングに関する軸を除く六軸でBaseとRandomの両方を有意に上回った（Holm補正後 $p < .05$ ）．支援スタイルの強さはBase，BASiS，Randomの順に4.22，5.64，3.97，ESConvらしい語調は4.59，6.17，4.43であった．有意な軸のKendallのWは.479-.876であった．助言のタイミングもBASiSの平均値が最も高かったが，対応比較は有意ではなかった．最終選択では，BASiSが74.4%で選ばれた．

図4の実験条件1におけるOracle評価でも，BASiSは全七軸で最高平均値を示した．Style StrengthではBase，Target-only，BASiS，Randomの順に8.26，8.22，8.65，8.21，ESConv Tone Similarityでは8.21，8.25，8.52，8.13であり，BASiSは両軸で三条件すべてを有意に上回った．Premature Advice




Fig. 3. ESConvとDailyDialogを用いた実験の人手評価結果。棒は参加者ごとの10件の平均値，エラーバーは参加者単位のブートストラップ95%信頼区間を表す。括弧はBASISと各比較条件との有意な対応比較を表す（三組の比較に対するHolm補正後；* $p < .05$, ** $p < .01$ ）。




Fig. 4. ESConvとDailyDialogを用いた実験におけるOracle評価結果。棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す。括弧は六組の比較に対するHolm補正後の有意な対応比較を表す（* $p < .05$, ** $p < .01$, *** $p < .001$ ）。

Avoidanceでも8.57, 8.76, 9.44, 8.92となり，三条件すべてとの差が有意であった。NaturalnessはRandomを有意に上回り，Target-onlyはいずれの軸でもBaseを有意に上回らなかった。

実験条件2：MathDial × WildChat-1M

図5に実験条件2における人手評価の結果を示す。BASISは七軸すべてでBaseとRandomの両方を有意に上回った（Holm補正後 $p < .05$ ）。Equitable Tutoringは4.28, 5.42, 3.73, Feedback Actionabilityは4.13, 5.43, 3.72であり，学習者自身の思考を促すことと，次に行う行動を明確にすることの双方で改善が確認された。各軸のKendallのWは.716-.939であった。最終選択では，BASISが61.1%で選ばれた。

図6の実験条件2におけるOracle評価では，BASISが七軸すべてで三つの比較条件を上回り，全21比較が有意であった（すべて $p < .001$ ）。Equitable TutoringではBase, Target-only, BASIS, Randomの順に6.77, 7.02, 7.75, 6.00であった。Learner Reasoning Diagnosisは7.38, 7.76, 8.70, 6.97, Mistake Location and Targetingは7.53, 7.74, 8.85, 7.27であった。Feedback ActionabilityにおけるBASISとRandomの差は1.85ポイントで，七軸中最大であった。Target-onlyは全軸でBaseより高い平均値を示したが，差は有意ではなかった。

実験条件3：MediTOD × WildChat-1M

図7に実験条件3における人手評価の結果を示す。BASISは五軸すべてで最高平均値を示した。Premature Assessment Avoidance, Unsafe Medical Advice Avoidance, Unsupported Diagnosis Avoidanceでは，BaseとRandomの両方を有意に上回り（Holm補正後 $p < .05$ ），KendallのWは.799-.813であった。Coverage Without RedundancyとAppropriate UncertaintyではFriedman検定が有意ではなかった。最終選択では，BASISが44.3%と最も多く選ばれた。

図8の実験条件3におけるOracle評価でも，BASISは全七軸で最高平均値を示した。Response RelevanceではBase, Target-only, BASIS, Randomの順に4.46, 4.70, 5.09, 4.91, Overall Qualityでは5.16, 5.26, 5.69, 5.46であった。Appropriate Uncertaintyでは7.84, 7.96, 8.26, 7.92となり，BASISは三条件すべてを有意に上回った。Unsafe Medical Advice AvoidanceはRandomを，Unsupported Diagnosis




Fig. 5. MathDialとWildChat-1Mを用いた実験の人手評価結果．棒とエラーバーは参加者ごとの平均値とブートストラップ95%信頼区間を表す．括弧はBASiSと各比較条件とのHolm補正後の有意な対応比較を表す（* $p < .05$, ** $p < .01$ ）．




Fig. 6. MathDialとWildChat-1Mを用いた実験におけるOracle評価結果．棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧は六組の比較に対するHolm補正後の有意な対応比較を表す（すべて*** $p < .001$ ）．




Fig. 7. MediTODとWildChat-1Mを用いた実験の人手評価結果．棒とエラーバーは完全回答者7名の平均値と参加者単位のブートストラップ95%信頼区間を表す．括弧はBASiSと各比較条件とのHolm補正後の有意な対応比較を表す（* $p < .05$ ）．




Fig. 8. MediTODとWildChat-1Mを用いた実験におけるOracle評価結果．棒は各条件の平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧は六組の比較に対するHolm補正後の有意な対応比較を表す（* $p < .05$, ** $p < .01$ ）．

AvoidanceはBaseとRandomを有意に上回った．Target-onlyはMediTODでもBaseを有意に上回る軸がなかった．

表5に最終選択の分布をまとめる．BASiSの選択率はESConvで74.4%，MathDialで61.1%，MediTODで44.3%となり，三領域すべてで最も多く選ばれた．MediTODでは過半数には達していないが，Randomを17.2ポイント上回った．

Table 5. 人手評価における最終選択の件数と割合

選択	ESConv	MathDial	Medi TOD
Base	14 (15.6%)	16 (17.8%)	11 (15.7%)
BASiS	67 (74.4%)	55 (61.1%)	31 (44.3%)
Random	6 (6.7%)	12 (13.3%)	19 (27.1%)
ほぼ同じ	2 (2.2%)	3 (3.3%)	8 (11.4%)
判断できない	1 (1.1%)	4 (4.4%)	1 (1.4%)

4.5 考察

本実験では、感情支援、数学チュータリング、医療問診という性質の異なる三種類の目的特化対話を対象としてBASiSを評価した。人手評価では全19軸で最高平均値を示し、BaseとRandomをそれぞれ16軸で有意に上回った。最終選択でも、三領域すべてでBASiSが最も多く選ばれた。Oracle評価でも全21軸で最高平均値を示し、Base、Target-only、Randomに対して、それぞれ18軸、13軸、15軸で有意に高かった。以下では、これらの結果が示すBASiSの強みと、その理由を考察する。

考察1：感情支援対話における会話スタイルの再現

人手評価では、支援スタイルの強さ、温かく受容的な語調、支援者としての一貫性、非指示性、文脈への適合、自然さの六軸で、BASiSがBaseとRandomを上回った。さらに、最終選択では74.4%を占めた。個々の表現だけでなく、気持ちを受け止める姿勢、押し付けを避ける方針、会話への適合が同時に高く評価されたことから、BASiSはESConvに特徴的な支援者の振る舞いを一体として応答へ反映できたと考えられる。これは、reflect_validateなどの応答戦略と共感的支援へ進む状態遷移に適合するデータを選ぶことで、単に柔らかい語句を増やすのではなく、支援者としての役割を保つ応答を学習できたためと考えられる。助言のタイミングを表すPremature Advice Avoidanceも人手評価ではBASiSが最高平均値を示し、Oracle評価では三つの比較条件を有意に上回った。人手評価の対応比較は有意ではなかったものの、両評価の平均値は同じ方向を示している。したがって、助言を急がない傾向もBASiSの特徴として表れており、より多くの対話例を用いることで人間が感じる差をさらに明確に捉えられると考えられる。

考察2：数学チュータリングにおける教育的対話方針の再現

人手評価では、学習者の思考を促すこと、推論の診断、誤りの特定、支援内容の有用性、解答提示の調整、会話段階との適合という七軸すべてで、BASiSがBaseとRandomを上回った。最終選択でも61.1%を占め、教育的な応答としての総合的な望ましさが人間の判断から支持された。Oracle評価でも、Target-onlyを含む三条件との全比較が有意であり、数学チュータリングでは特に一貫した効果が得られた。中でも、人が次に考え、計算し、確認すべき行動の明確さを表すFeedback Actionabilityで大きな差が得られた。BASiSは、学習者の推論状態から質問、ヒント、説明へ進むMathDialの遷移に整合するデータを選別する。そのため、正解を提示するだけでなく、学習者が次の推論へ移れる足場を含む応答が学習され、Equitable TutoringやTeacher Move-Stage Alignmentを含む幅広い評価につながったと考えられる。

考察3：医療問診における応答品質と安全性

人手評価では、情報不足時に評価を急がないこと、危険な医学的助言を避けること、根拠のない診断を避けることの三軸で、BASiSがBaseとRandomを上回った。最終選択でも44.3%と最も多く選ばれ、Randomを17.2ポイント上回った。したがって、BASiSの強みは、医療問診において特に重要な「情報が揃うまで判断を保留する」という慎重な応答方針に表れたと考えられる。状態遷移に基づいて候補を評価することで、症状に関連する語を含むだけでなく、確認を重ねてから判断へ進む応答を選別できたためだ

と考えられる。Coverage Without RedundancyとAppropriate Uncertaintyは人手評価の条件差が有意ではなかったが、BASiSはいずれも最高平均値を示した。また、Oracle評価ではAppropriate Uncertaintyが三条件すべてを上回った。これらを踏まえると、BASiSの効果はまず安全性に直結する断定回避で明確に現れ、情報収集の効率や不確実性の表現には対話文脈による幅があると考えられる。今後、症状や会話段階の多様性を広げることで、これらの側面もより詳細に評価できる。

考察4：応答内容ではなく対話の進め方を選別する効果

三領域に共通して高く評価されたのは、単なる話題や語調ではなく、応答のタイミングと会話段階に沿った進め方である。感情支援では気持ちを受け止める姿勢、数学チューティングでは学習者を次の思考へ導く足場、医療問診では情報不足時に断定を避ける慎重さが、人手評価で明確に支持された。これらは、いずれも会話履歴と現在の段階を踏まえなければ実現できない応答方針である。この結果は、式(3)の設計と整合する。BASiSは、候補応答を単一ターンの一般的な品質ではなく、その応答によって望ましい状態へ進む確率に基づいて評価する。そのため、小規模コーパスに含まれる「どの段階で、どのように応答するか」という知識が選別データへ反映され、人間が対話全体として望ましいと感じる応答につながったと考えられる。

考察5：小規模目的コーパスとデータ選別の寄与

Oracle評価では、Target-onlyが21軸のいずれでもBaseを有意に上回らなかったのに対し、BASiSはTarget-onlyを13軸で上回った。したがって、小規模目的コーパスは、そのまま学習するデータとしてだけでなく、対話構造を抽出して大規模コーパスを選ぶ基準として用いることで、より強く活用できると考えられる。また、BASiSはRandomより全21軸で高い平均値を示し、人手評価でも19軸中16軸で上回った。両条件は学習データ数と学習設定が共通であり、Randomも話題カテゴリで絞り込まれている。それでも一貫した差が得られたことから、目的特化対話への適応には、話題の一致に加えて、対話状態・応答戦略・状態遷移に整合するデータを選ぶことが重要だと考えられる。

考察6：三つの目的特化対話への適用可能性

BASiSは、参照元と選別対象のコーパスを変更するだけで、同一のパイプラインを三領域へ適用した。人手評価とOracle評価の全評価軸で最高平均値を示し、最終選択でも三領域すべてで最も多く選ばれたことから、BASiSは特定の語調に限定されず、各目的コーパスに固有の応答方針を抽出してモデルへ反映できると考えられる。領域ごとに強く改善した側面が異なったことも、単一の固定ガイドラインではなく、各コーパスから状態・戦略を誘導する設計の利点を示している。したがって、今回の結果はBASiSの有効性を示す明確な初期的根拠である一方、利用者層全体への一般化には、外部評価者とより多くの対話例による検証が必要である。今後は対象を広げるとともに、目的ごとの状態・戦略・望ましい状態群の設計を洗練することで、BASiSの強みをより多様な目的特化対話へ展開できると考えられる。

5 結論

本研究では、小規模高品質コーパスに基づくベイズ的データ選別によって、目的特化対話に求められる会話スタイルをローカル大規模言語モデル（LLM）へ反映する手法BASiS（Bayesian Style-based Selection）を提案した。BASiSは、小規模コーパスから制約付きのラベル体系誘導によって会話状態・応答戦略・状態遷移を導出し、ベイズ的対話モデルとして表現する。このモデルを用いて大規模汎用コーパスの候補応答を評価し、得られた選好データによってローカルLLMを学習する。この仕組みにより、目的ごとの詳細な対話ガイドラインを手で記述することなく、小規模コーパスに含まれる応答方針と複数ターンにわたる対話の進め方を、学習データの選別基準として利用できる。また、会話状態を確率分布として扱い、候補応答

から得た観測によって更新することで、会話履歴と応答後の状態遷移を考慮して目的に適したデータを選別できる。

異なる性質を持つ三種類の目的特化対話を対象とした比較実験では、人手評価の全19軸でBASiSが最高平均値を示し、三領域すべての最終選択で最も多く選ばれた。Oracle評価でも全21軸で最高平均値を示した。これらの結果から、共感的な支援方針、学習者の理解状態に応じた教育的支援、および情報不足時に断定を避ける応答方針を、目的に応じてモデルへ反映できる可能性が示された。また、Oracle評価ではTarget-onlyがBaseを有意に上回る軸がなく、Randomとの比較でもBASiSが広い範囲で優位であったことから、小規模コーパスを対話構造の抽出元として活用し、粗い話題の一致を超えて学習データを選ぶことの重要性が示された。

今後は、異なるモデルへの適用可能性を評価するとともに、目的に応じた会話状態・応答戦略・望ましい状態群の設計方法を検討する。さらに、外部評価者とより多くの対話例を用いた人手評価を行い、カウンセリング、教育、医療をはじめとする多様な目的特化対話への応用可能性を検証する。

References

- [1] Lichang Chen, Shiyang Li, Jun Yan, Hai Wang, Kalpa Gunaratna, Vikas Yadav, Zheng Tang, Vijay Srinivasan, Tianyi Zhou, Heng Huang, and Hongxia Jin. 2024. AlpaGasus: Training a Better Alpaca with Fewer Data. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=FdVXgSJhvz>
- [2] Ananya Ganes, Martha Palmer, and Katharina Kann. 2021. What Would a Teacher Do? Predicting Future Talk Moves. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*. Association for Computational Linguistics, Online, 4739–4751. doi:10.18653/v1/2021.findings-acl.418
- [3] Prakhar Gupta, Yang Liu, Di Jin, Behnam Hedayatnia, Spandana Gella, Sijia Liu, Patrick Lange, Julia Hirschberg, and Dilek Hakkani-Tur. 2023. DialGuide: Aligning Dialogue Model Behavior with Developer Guidelines. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 14031–14047. doi:10.18653/v1/2023.findings-emnlp.935
- [4] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2022. LoRA: Low-Rank Adaptation of Large Language Models. The Tenth International Conference on Learning Representations (ICLR 2022). <https://openreview.net/forum?id=nZvKeeFYf9>
- [5] Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. DailyDialog: A Manually Labelled Multi-turn Dialogue Dataset. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Asian Federation of Natural Language Processing, Taipei, Taiwan, 986–995. <https://aclanthology.org/I17-1099/>
- [6] Siyang Liu, Chujie Zheng, Orianna Demasi, Sahand Sabour, Yu Li, Zhou Yu, Yong Jiang, and Minlie Huang. 2021. Towards Emotional Support Dialog Systems. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, Online, 3469–3483. doi:10.18653/v1/2021.acl-long.269
- [7] Wei Liu, Weihao Zeng, Keqing He, Yong Jiang, and Junxian He. 2024. What Makes Good Data for Alignment? A Comprehensive Study of Automatic Data Selection in Instruction Tuning. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=BTKAeLqLMw>
- [8] Jakub Macina, Nico Daheim, Sankalan Pal Chowdhury, Tanmay Sinha, Manu Kapur, Iryna Gurevych, and Mrinmaya Sachan. 2023. MathDial: A Dialogue Tutoring Dataset with Rich Pedagogical Properties Grounded in Math Reasoning Problems. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 5602–5621. doi:10.18653/v1/2023.findings-emnlp.372
- [9] Remi Mir, Bjarke Felbo, Nick Obradovich, and Iyad Rahwan. 2019. Evaluating Style Transfer for Text. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Association for Computational Linguistics, Minneapolis, Minnesota, 495–504. doi:10.18653/v1/N19-1049
- [10] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. 2022. Training Language Models to Follow Instructions with Human Feedback. In *Advances in Neural Information Processing Systems*, Vol. 35. Curran Associates, Inc., Red Hook, NY, USA, 27730–27744.
- [11] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. 2023. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 53728–53741. doi:10.52202/075280-2338
- [12] Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. 2019. Towards Empathetic Open-domain Conversation Models: A New Benchmark and Dataset. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational

- Linguistics, Florence, Italy, 5370–5381. doi:10.18653/v1/P19-1534
- [13] Eric Rudolph, Philipp Steigerwald, and Jens Albrecht. 2026. Transition-Matrix Regularization for Next Dialogue Act Prediction in Counselling Conversations. In *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics, San Diego, California, United States, 25442–25457. doi:10.18653/v1/2026.findings-acl.1271
- [14] Vishal Vivek Saley, Goonjan Saha, Rocktim Jyoti Das, Dinesh Raghu, and Mausam. 2024. MediTOD: An English Dialogue Dataset for Medical History Taking with Comprehensive Annotations. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Miami, Florida, USA, 16843–16877. doi:10.18653/v1/2024.emnlp-main.936
- [15] Chenwei Wan, Matthieu Labeau, and Chloé Clavel. 2025. EmoDynamix: Emotional Support Dialogue Strategy Prediction by Modelling MiXed Emotions and Discourse Dynamics. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Association for Computational Linguistics, Albuquerque, New Mexico, 1678–1695. doi:10.18653/v1/2025.naacl-long.81
- [16] Xiangyu Wen, Jianyuan Zhong, Zhijian Xu, and Qiang Xu. 2025. Guideline Compliance in Task-Oriented Dialogue: The Chained Prior Approach. In *Findings of the Association for Computational Linguistics: NAACL 2025*. Association for Computational Linguistics, Albuquerque, New Mexico, 6765–6791. doi:10.18653/v1/2025.findings-naacl.377
- [17] Mengzhou Xia, Sadhika Malladi, Suchin Gururangan, Sanjeev Arora, and Danqi Chen. 2024. LESS: Selecting Influential Data for Targeted Instruction Tuning. In *Proceedings of the 41st International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 235)*. PMLR, Vienna, Austria, 54104–54132. <https://proceedings.mlr.press/v235/xia24c.html>
- [18] Bolin Zhang, Jiahao Wang, Qianlong Du, Jiajun Zhang, Zhiying Tu, and Dianhui Chu. 2025. A Survey on Data Selection for LLM Instruction Tuning. *Journal of Artificial Intelligence Research* 83, Article 32 (2025), 14 pages. doi:10.1613/jair.1.17625
- [19] Saizheng Zhang, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela, and Jason Weston. 2018. Personalizing Dialogue Agents: I have a dog, do you have pets too?. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, Melbourne, Australia, 2204–2213. doi:10.18653/v1/P18-1205
- [20] Wenting Zhao, Xiang Ren, Jack Hessel, Claire Cardie, Yejin Choi, and Yuntian Deng. 2024. WildChat: 1M ChatGPT Interaction Logs in the Wild. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=Bl8u7ZRlbM>
- [21] Chunting Zhou, Pengfei Liu, Puxin Xu, Srinu Iyer, Jiao Sun, Yuning Mao, Xuezhe Ma, Avia Efrat, Ping Yu, Lili Yu, Susan Zhang, Gargi Ghosh, Mike Lewis, Luke Zettlemoyer, and Omer Levy. 2023. LIMA: Less Is More for Alignment. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 55006–55021. doi:10.52202/075280-2400