

BASiS:

ベイズ的データ選別による 対話進行パターンの言語モデルへの反映

ANONYMOUS AUTHOR(S)

本論文では、小規模高品質な対話コーパスを単なる発話例の集合として利用するのではなく、そこに暗黙に含まれる対話の進め方を、会話状態の遷移と各状態における応答戦略の確率分布としてモデル化し、このモデルを大規模汎用コーパスから学習データを選ぶ基準へ転用する手法BASiS (Bayesian Style-based Selection) を提案する。本研究は、相手の状態や対話局面に応じて対話を進行させる必要がある場面に着目する。こうした対話の質を支えるのは、個々の発話内容だけではなく、相手の状況をどのように捉え、どのタイミングでどの対話方策を用いるかという、インタラクションにおける手続き的知識である。しかし、このような知識は小規模な高品質対話コーパスに暗黙的に含まれている一方、そのままでは大規模なLLM学習に十分なデータ量を確保できない。BASiSは、この知識を会話状態・応答戦略・状態遷移の確率モデルとして抽出し、大規模汎用コーパスの学習データ選別基準へ変換することで、少量の高品質対話に含まれる知識を大規模学習へスケールさせる。BASiSでは、小規模コーパスから会話状態、応答戦略、状態遷移を抽出し、それらをベイズ的対話モデルとして表現する。次に、大規模コーパスに含まれる対話を、参照コーパスの対話進行との適合度に基づいてスコアリングし、学習データを選別する。さらに、選別したデータから選好ペアを構築し、Direct Preference Optimization (DPO) を用いてLLMを学習する。これにより、詳細な対話ガイドラインを人手で設計する負担を軽減しながら、一般的な品質や話題の類似性だけでは捉えにくい応答のタイミングや複数ターンにわたる対話の進行を、データ選別に反映できる。また、単一の応答戦略に固定するのではなく、会話状態を確率分布として保持することで、同一の文脈に対する複数の妥当な応答戦略を維持できる。感情支援、数学チュータリング、医療問診を対象として、学習前のベースモデル、BASiSによる選別データで学習したモデル、および目的コーパスのカテゴリ内から無作為に選別したデータで学習したモデルを比較することで、BASiSを評価した。人手評価では、BASiSは全19評価軸で最高平均値を示し、三領域すべてで最終選択として最も多く選ばれた。LLMによる大規模評価では、BASiSは全21評価軸で最高平均値を示し、感情支援と数学チュータリングでは広範な有意改善が確認された。

CCS Concepts: • **Computing methodologies** → **Natural language generation**; **Discourse, dialogue and pragmatics**; Learning from implicit feedback; • **Human-centered computing** → **Natural language interfaces**.

Additional Key Words and Phrases: 対話進行, データ選別, ベイズ的対話モデリング, 応答戦略, 選好最適化, 感情支援対話, 大規模言語モデル

ACM Reference Format:

Anonymous Author(s). 2026. BASiS: ベイズ的データ選別による 対話進行パターンの言語モデルへの反映. In *Proceedings of 32nd Annual ACM Conference on Intelligent User Interfaces (IUI '27)*. ACM, New York, NY, USA, 15 pages.

1 はじめに

Instruction tuningやRLHFの発展により、近年の大規模言語モデル (LLM) は、指示に従って正確な応答を生成し、多様な話題について自然で一貫した複数ターン対話を行えるようになった[10]。一方、感情支援、数学チュータリング、医療問診などでは、正しい情報を提示するだけでなく、相手の状態や対話の段階に応

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM.

Manuscript submitted to ACM

Manuscript submitted to ACM

じて適切な応答戦略を選ぶ必要がある[6, 12]. 例えば数学教育では, 単に正答を提示するのではなく, 学習者の現在の考え方を把握したうえで, 学習者が自力で次の段階へ進めるように, 質問, ヒント, 説明を使い分ける必要がある. このような応答を実現するには, 複数ターンにわたる対話進行を適切に制御する必要がある.

LLMによる応答生成では, この要件に対して主に二つの方法が検討されてきた. 一つは, 望ましい応答戦略を自然言語の対話ガイドラインとして記述し, それに従うよう生成を制御する方法である[3, 16]. もう一つは, Instruction tuningや高品質な学習例の選別を通じて, データからモデルの振る舞いを学習させる方法である[18, 21]. 前者では, 応答のタイミングや複数ターンの進行といった暗黙的な特徴を含む対話ガイドラインを, 設定ごとに人手で設計する必要がある. 後者では十分な学習データが必要となるが, 詳細な相互作用上の知識は, LLMの学習には量が不足する小規模な高品質対話コーパスに含まれていることが多い.

これとは別に, 対話行動, 応答戦略, およびそれらの遷移によって対話進行をモデル化する研究が行われている. Ganeshらは授業対話における教師の次のtalk moveを予測し[2], Wanらはユーザの感情状態と応答戦略の関係を異種グラフとしてモデル化した[15]. Rudolphらは, カウンセリング対話から得た遷移行列を次対話行為予測の正則化に用いた[13]. これらの研究は, 個々の発話表現を超えた重要な対話構造を捉えているが, 主な評価対象は行動や戦略の予測である. LLMによる自然言語応答生成との統合や, モデル化した対話進行が生成応答に現れるかの評価は, 依然として限定的である.

これら二つの研究系統を統合するため, 本研究では, 小規模高品質コーパスの対話進行をLLMへ反映する手法BASiS (Bayesian Style-based Selection) を提案する. BASiSは, まず小規模コーパスから, 会話状態, 応答戦略, 状態遷移, およびそれらの確率的関係からなる対話進行モデルを誘導する. 次に, その進行との適合性に基づいて大規模汎用コーパスの候補応答をスコアリングし, 選好ペアを構築する. 最後に, Direct Preference Optimization (DPO) [11]とLow-Rank Adaptation (LoRA) [4]を用いてLLMを適応させる. これにより, 小規模コーパスに含まれる相互作用上の知識を大規模コーパスの選別を通じて拡張するとともに, 詳細な対話ガイドラインを人手で設計する負担を軽減する. また, 会話状態を確率分布として保持することで, 会話履歴と複数の妥当な応答戦略を考慮できる. 参照コーパスと候補プールを変更し, 同一のパイプラインを感情支援, 数学チュータリング, 医療問診の三領域で評価する.

本論文の構成は以下の通りである. 第2章では, ガイドラインに基づく応答制御, 対話履歴に基づく対話行動・応答戦略予測, およびLLMの学習データ選別に関する関連研究を紹介する. 第3章では, 提案手法BASiSのパイプラインを構成する4つの工程を述べる. 第4章では, 評価設計, 結果, および考察について述べる. 最後に, 第5章で本研究をまとめる.

2 関連研究

ガイドラインに基づく方法では, 望ましい対話の振る舞いを明示し, 応答生成の制御に用いる. DialGuideは, 各ガイドラインを, 適用される文脈を示す自然言語の条件と, 応答に含める内容を示す行動として表現する[3]. 現在の対話文脈に関連するガイドラインを検索し, それに基づく応答の生成または検証を行う. 一方, GuidedTODは, 運用ガイドラインに記述された行動をChained Priorと呼ばれるマルコフ連鎖の状態として表し, 整備されたサービスデータから遷移確率を校正する[16]. 推論時には, 対話の進行に応じてChained Priorを更新し, 候補出力の再ランキングに用いる. これらの研究は, 明示的な対話ガイドラインによって, 現在の対話段階に沿って応答生成や応答選択を制御できることを示している. ただし, 対話ガイドラインは開発者が記述する必要がある, 望ましい対話進行が変わるたびに再設計しなければならない.

対話進行は、コーパスからモデル化することもできる。Ganeshらは、それまでの授業対話とtalk moveから、教師が次を取るtalk moveを予測する[2]。EmoDynamixは、ユーザの細粒度な感情状態とシステムの応答戦略との談話的な関係を、異種グラフとして表現する[15]。Rudolphらは、カウンセリング対話から対話行為の遷移パターンを推定し、観測された対話の流れに沿うように次対話行為予測を正則化する[13]。これらの研究は、対話進行を、人手で記述した規則だけでなく、コーパスから得られる状態、行動、戦略、遷移の構造として表現できることを示している。

データ中心のアプローチでは、大規模な候補集合から学習例を選別することで、LLMの振る舞いを効率的に適応させている。LIMAは、データの品質と多様性を重視した慎重な選定を行う[21]。AlpaGasusはLLMによる品質スコアを用いて指示データを選別し、DEITAは指示の複雑さ、応答の品質、多様性を組み合わせてデータを選ぶ[1, 7]。LESSは、個々の学習例が下流の性能に与える影響を推定し、有用性が高いと見込まれる例を選別する[17]。これらの研究は、望ましい振る舞いや能力を表す基準を設けることで、LLMの適応に有効なデータを構築できることを示している。

コーパスに基づく対話進行のモデル化とデータ中心のLLM適応を踏まえると、コーパスから抽出した対話進行をLLMの学習データ選別基準として用いる、という新たな研究方向が導かれる。例えば数学チュータリングでは、応答の適切さは、単独の発話としての品質や話題との関連性だけでなく、学習者の現在の状態、それまでのやり取り、および応答によって対話をどの段階へ進めるかにも依存する。しかし、前述の対話モデルは、主として次の行動や戦略の予測に対話構造を用いており、自然言語応答の学習には利用していない。一方、前述のデータ選別手法は、品質、複雑さ、多様性、下流性能への影響に基づいて学習例を評価するが、高品質な対話コーパスから学習した複数ターンの進行に照らして、各応答が対話をどのように前進させるかは表現していない。BASiSは、小規模高品質コーパスに暗黙に含まれる対話進行を確率的な選別基準へ変換し、さらにLLM適応用の選好データへ変換することで、この課題に取り組む。これにより、開発者が望ましい対話進行全体をガイドラインとして記述することなく、コーパスから得た相互作用上の知識を大規模なLLM学習へ展開し、生成応答に反映できる。

3 BASiS

3.1 コンセプト

本研究では、小規模高品質コーパスに含まれる対話進行を、ベイズ的データ選別によってLLMへ反映する手法BASiSを提案する。BASiSの目的は、小規模コーパスに暗黙的に表れる応答戦略や対話進行パターンを、LLMの学習に利用できる形へ変換することである。小規模高品質コーパスをそのまま学習に用いるのではなく、そこから会話状態、応答戦略、状態遷移を抽出して確率的な対話モデルを構築し、大規模汎用コーパスの選別基準として利用する。BASiSにより、大規模汎用コーパスに含まれる各対話データを、目的コーパスの対話進行との適合度に基づいて評価できる。設定ごとの詳細な対話ガイドラインの手動記述を前提とせず、小規模コーパスに含まれる相互作用上の知識を学習データへ反映する。また、会話状態を一つに決定せず確率分布として保持することで、同一の文脈に対して複数の応答戦略が妥当となる会話の多様性を扱う。最終的に、選別したデータを用いてDPO学習を行い、小規模コーパスの対話進行パターンをLLMへ反映する。

3.2 BASiSのパイプライン

BASiSの4つの工程を図1に示す。上段Aの*Dialogue Progression Modeling*は工程1と工程2からなる。工程1では、小規模高品質コーパスの会話本文と既存アノテーションを入力とし、コーパス固有の会話状態、応答戦




Fig. 1. BASiSのバイブライン。上段では、小規模高品質コーパスから会話特徴と確率の推定値を抽出し、ベイズ的対話モデルとして定式化する。下段では、固定済みのモデルによって大規模汎用コーパスの候補応答をスコアリングし、得られた選好データを用いてLoRAアダプタをDPOで学習する。①-④は本文で説明する4つの工程に対応する。

略、状態遷移、および確率の推定値を出力する。工程2では、これらの出力を入力として確率値を正規化し、固定されたベイズ的対話モデルとして整理する。下段BのData Selection & Adaptationは工程3と工程4からなる。工程3では、固定済みのベイズ的対話モデルと、大規模汎用コーパスからなる候補プールの対話データを入力とし、各候補応答に0から1の対話進行適合度スコアを付与する。工程4では、候補応答とそのスコアからchosen応答とrejected応答の選好ペアを構築し、DPOで学習したLoRAアダプタを出力する。このアダプタをベースLLMへ適用することで、参照コーパスの対話進行パターンを反映したモデルが得られる。したがって、小規模コーパスは対話進行を抽出する参照元、大規模コーパスは学習候補データの供給元として役割が分かれている。両コーパスを変更することで、異なる対話領域にも同一のバイブラインを適用できる。

工程1：会話特徴分析 (Dialogue Feature Analysis)

工程1の入力は、小規模高品質コーパスから抽出した80会話の本文と既存アノテーションである。80会話は分割せず、一度のプロンプトですべてLLMへ提示した。出力は、コーパスに含まれる会話状態、応答戦略、状態遷移、およびそれらの確率の推定値からなる対話進行の表現である。各ターンについて、会話状態は対話相手の状況または現在の対話段階、応答戦略は個々の応答が果たす観測可能な機能、状態遷移は応答前の状態から応答後の状態への移行を表す。

プロンプトでは、抽出した会話全体を通して意味の近いラベルを統合し、会話状態を4-7個とし、会話状態と応答戦略を異なる概念として定義した上で、各ターンにラベルを付与し、望ましい対話進行を表す状態を特定するよう指示した。既存アノテーションは各ターンの機能を判断する根拠として用いるが、その名称を会話状態として機械的に転用するわけではない。初期状態確率、状態遷移確率、観測尤度はラベルの出現頻度から算出せず、LLMにコーパス全体の傾向を表す数値として出力させた。出力後には、ラベルの欠落、各確率が[0, 1]の範囲内にあるか、確率分布の各行の総和が1であるかを検査し、必要な行は工程2で正規化した。例えば、本実験で使用する感情支援対話コーパスESConv[6]からは、挨拶や短い安否確認を通じて相談者が安心して話せる雰囲気を作る状態のopening_rapportと、相談者の感情を受け止めて孤立感や心理的負担を和らげる状態のempathic_supportが生成された。また、状況を理解するために文脈に




Fig. 2. 工程3における候補応答の評価処理の模式例．パネル (a) – (e) は、事前状態分布の設定、予測、応答ラベルの付与、ベイズ更新、対話進行適合度スコアの算出という五つの内部処理を示す．青色と橙色の経路は、予測分布と観測ラベルが更新式のどの項へ入力されるかを表す．例では、対象状態ProcessingとSolutionsの確率を合計し、Score = 0.88を得る．

沿って質問する応答戦略のexplore_questionと、発言内容や感情を言い換えて認めるreflect_validateが生成された．

工程2：ベイズ対話モデル構築 (Bayesian Dialogue Modeling)

工程2では、工程1が出力したラベルと確率の推定値を入力とし、参照コーパスの対話進行を表す正規化済みの固定ベイズモデルを出力する．会話状態の集合を $S = \{s_1, \dots, s_K\}$ 、応答戦略に対応する観測ラベルの集合を $O = \{o_1, \dots, o_L\}$ とする．ベイズ的対話モデルは、初期状態確率 $P(s_1)$ 、状態遷移確率 $P(s_t | s_{t-1})$ と観測尤度 $P(o_t | s_t)$ から構成される．状態遷移確率は、参照コーパスから抽出した会話を基に推定した、会話状態 s_{t-1} から s_t へ移行する相対的な傾向を表す．観測尤度は、会話が状態 s_t にあるときに、応答戦略 o_t が観測される確率を表す．工程2では、工程1の推定値を妥当な確率分布へ正規化し、初期状態分布、状態遷移行列、観測尤度行列として固定する．この工程では、新たなコーパス分析やモデル学習は行わない．構築したモデルは、小規模コーパス中の発言を記憶するのではなく、状態と戦略の確率的な関係を表すため、コーパスに含まれていない候補応答にも適用できる．また、工程3ではモデルのパラメータを更新せず、固定したまま使用する．

工程3：対話進行スコアリング (Dialogue Progression Scoring)

工程3では、工程2で固定したベイズ的対話モデルと、大規模汎用コーパスの会話履歴および候補応答を入力とする．ここではモデルを新たに構築または学習せず、各候補応答にベイズ推論を適用して対話進行適合度スコアを出力する．図2では、工程3の内部処理を、(a) 事前状態分布の設定、(b) 次状態分布の予測、(c) 候補応答へのラベル付与、(d) 状態分布のベイズ更新、(e) スコア算出の五つに分けて示す．

各候補応答に対する状態分布を構築するため、大規模コーパスをconversation ID単位にまとめ、各会話の先頭からturn index順に処理した．最初の評価対象応答では、工程2で固定した初期状態分布から開始する．それ以前の応答には順に応答戦略ラベルを付与してベイズ更新を行い、得られた事後分布を次の応答の事前分布として引き継ぐ．応答ラベル付与時にLLMへ提示する会話履歴は、会話先頭からの全履歴とした．

はじめに、候補応答が提示される前の対話状態を、一つの状態に固定するのではなく、状態集合 S 上の確率分布として保持する（図2のパネル (a)）．図の例では、ターン $t-1$ までの状態分布 $b_{t-1}(s)$ として、Emotion disclosureに0.30、Emotion processingに0.45、Considering solutionsに0.25を割り当てている．次

に、固定済みの状態遷移確率を用いて、ターン t における状態の予測分布を次式によって計算する（パネル (b)）。

$$\hat{b}_t(s_t) = \sum_{s_{t-1} \in S} P(s_t | s_{t-1}) b_{t-1}(s_{t-1}). \quad (1)$$

図2のパネル (b) に示す状態遷移図は、Disclosure, Processing, Solutionsという状態間の遷移と、各遷移で観測される代表的な応答戦略の対応を模式的に示す。式(1)では、これらの遷移の出現傾向を表す $P(s_t | s_{t-1})$ によって、直前の分布 b_{t-1} を予測分布 $\hat{b}_t$ へ写像する。

続いて、LLMが候補応答 r_t を、固定済みの応答戦略ラベルの中から一つの観測ラベル o_t へ対応付ける（パネル (c)）。LLMには会話履歴、候補応答、許可されたラベルとその説明を提示し、新しいラベルや状態名を生成しないよう指示する。後続のベイズ計算で用いる出力は、選択された観測ラベルのみである。図の例では、候補応答“That sounds really difficult.”が*Empathy / validation*に分類される。LLMが会話状態を直接決定するのではなく、 o_t に対応する固定済みの観測尤度を用いて、予測分布 $\hat{b}_t(s_t)$ をベイズ則により更新する。

$$b_t(s_t) = \frac{P(o_t | s_t) \hat{b}_t(s_t)}{\sum_{s' \in S} P(o_t | s') \hat{b}_t(s')}. \quad (2)$$

ここで、 $b_t(s_t)$ は、それまでの観測を予測分布 $\hat{b}_t(s_t)$ に反映した上で、観測履歴 $o_{1:t}$ を条件とする事後確率 $P(s_t | o_{1:t})$ を表す。図2のパネル (d) では、橙色の経路が観測ラベル o_t によって尤度 $P(o_t | s_t)$ を定める流れ、青色の経路が予測分布 $\hat{b}_t(s_t)$ を更新式へ入力する流れを示す。分母は全状態について正規化を行い、更新後の確率の総和を1にする。この例では、更新後の確率はDisclosure, Processing, Solutionsの順に0.12, 0.66, 0.22となる。

最後に、対象とする対話進行において望ましいと定義された状態群を $S_{\text{target}} \subseteq S$ とし、候補応答 r_t の対話進行適合度スコアを、更新後の状態分布における S_{target} の確率の合計として定義する。

$$\text{Score}(r_t) = \sum_{s \in S_{\text{target}}} b_t(s). \quad (3)$$

対話進行適合度スコアは0から1までの値を取り、値が大きいほど、候補応答を観測した後の状態分布が、目的コーパスにおいて望ましい状態群と強く整合することを表す。図2のパネル (e) では、 $S_{\text{target}} = \{\text{Processing, Solutions}\}$ とし、 $0.66 + 0.22 = 0.88$ を候補応答の対話進行適合度スコアとしている。一般には、感情支援における感情の整理や適切な解決策の検討、数学チュータリングにおける学習者自身の推論の進展、医療問診における必要な症状情報の段階的な整理などを、対象領域に応じて S_{target} として設定できる。

このスコアリング処理では、次の応答戦略を一つの正解として固定せず、対話状態を確率分布として保持したまま候補応答を評価する。候補応答ごとに一つの観測ラベルを付与する場合でも、異なる応答戦略が望ましい状態群において高い観測尤度を持つならば、それぞれに対応する候補応答が高い対話進行適合度スコアを得られる。したがって、同一の文脈に複数の妥当な応答戦略が存在する場合も、単一の戦略に限定せず評価できる。

工程4：選好データ選別・DPO適応 (Preference Data Selection and DPO Adaptation)

工程4では、工程3が出力した候補応答と対話進行適合度スコアを入力とし、DPOで学習したLoRAアダプタを出力する。候補コーパスの各会話文脈には元から含まれる応答が1件あり、複数の代替応答があらかじめ

め用意されているわけではない。まず、これらの元応答をスコアリングし、高スコアの応答を *chosen* 候補として残す。次に、同一の会話文脈に対し、自然ではあるが応答戦略上は弱い応答をLLMで8件生成する。別の対話から取得した応答は *negative* として使用しない。8件すべてを *chosen* 候補と同じ応答直前の状態分布から再スコアリングし、*chosen* とのスコア差が最大となる応答を最終的な *rejected* とする。

BASiSの選好ペアには、*chosen* のスコアが0.70以上、*rejected* のスコアが0.55以下で、両者の差が0.20以上の組のみを採用した。構築した選好ペアは、Direct Preference Optimization (DPO) [11]に用いる。DPOは、*chosen* 応答が *rejected* 応答よりも選択されやすくなるようにモデルを直接最適化する。本研究では、モデル全体のパラメータを更新するのではなく、Low-Rank Adaptation (LoRA) [4]を適用し、追加された低ランクパラメータのみを更新する。得られたアダプタをベースLLMへ適用することで、モデルの一般的な言語生成能力を活用しながら、選別されたデータに含まれる対話進行を効率的に反映できる。

4 評価

4.1 研究質問

BASiSを評価するため、以下の二つの研究質問を設定する。

RQ1 (有効性) : BASiSは、小規模高品質な参照コーパスに含まれる対話進行を、生成応答へより適切に反映できるか。

RQ2 (データ選別の寄与) : コーパスから得た対話進行を適応用データの選別基準とすることで、この基準を用いない適応方法に対して、どのような追加効果が得られるか。

両研究質問を感情支援、数学チュータリング、医療問診で検証し、異なる対話進行の下でも同じ傾向が確認されるかを調べる。これらは性質の異なる三つの評価設定であり、未知の対話設定への一般化を主張するものではない。

4.2 評価設計

RQ1とRQ2に答えるため、三つの対話設定でBASiSを構築し、四つのモデル条件を二つの評価によって検証する。人手評価では、各設定に対して生成応答が適切であると人間が判断するかを直接調べる。LLMによる大規模評価では、各設定100件の対話文脈へ評価範囲を広げ、小規模コーパスを直接学習した条件も加えて比較する。以下では、三つの対話設定とモデル条件を示した後、各評価の設計を説明する。

4.2.1 対話設定とコーパス. 表1に示す三種類のコーパスペアを用いた。各設定では、小規模高品質コーパスを対話進行の参照元とし、大規模汎用コーパスをBASiSによる選別対象の候補プールとした。感情支援では、支援を求める話者と支援者の対話を収録したESConv[6]を小規模高品質コーパスとし、日常的な複数ターン対話からなるDailyDialog[5]を大規模汎用コーパスとした。数学チュータリングでは、教師とLLMが演じる学習者との一対一の数学対話を収録したMathDial[8]を小規模高品質コーパスとし、実環境におけるユーザとLLMの対話からなるWildChat-1M[20]を大規模汎用コーパスとした。医療問診では、医療従事者が作成した医師と患者の問診対話を収録するMediTOD[14]を小規模高品質コーパスとし、数学チュータリングと同様にWildChat-1Mを大規模汎用コーパスとした。工程1では、各参照コーパスから80会話を抽出した。抽出時には、ESConvではstrategy・emotion・problem、MathDialではteacher move、MediTODでは会話長の多様性を考慮した。

4.2.2 モデル条件と主要な比較.

Table 1. 評価に用いたコーパスペアと各コーパスの役割

対話設定	小規模高品質コーパス	大規模汎用コーパス
感情支援	ESConv	DailyDialog
数学チュータリング	MathDial	WildChat-1M
医療問診	Medi TOD	WildChat-1M

Table 2. 各モデル条件におけるDPO学習と学習データ

条件	DPO学習	学習データ
Base	×	なし
Target-only	✓	小規模目的コーパスのみ
BASiS	✓	対話進行に適合する選別データ
Random	✓	キーワードカテゴリ内で無作為

各設定のBASiS条件では、第3章の4工程によって選好ペアを構築した。ペア数はESConvとMathDialが各2,500組、Medi TODが2,324組である。比較条件として、小規模高品質コーパスから選好ペアを構築するTarget-only条件と、chosen応答の選別にBASiSのスコアを用いないRandom条件を設定した。

Random条件では、領域に関連する語を用いて大規模コーパスの候補集合を絞り込んだ。キーワードの例は、ESConvではsad, anxious, relationship problem, MathDialではlearn, tutor, math, Medi TODではsymptom, pain, doctorである。この候補集合に元から含まれる応答をseed 42で無作為に抽出し、chosen応答とした。同一の会話文脈に対して一般的に品質の低い応答を8件生成し、BASiSで再スコアリングした上で、chosenとの差が最大となる最低スコアの応答をrejectedとした。BASiSのスコアはrejectedの選択にのみ使用し、Randomのchosen応答の選別には用いていない。ペア数はBASiS条件と揃えた。

Target-only条件では、各参照コーパスのtrain splitに元から含まれる応答をchosenとした。同一文脈に対して弱い応答を8件生成して再スコアリングし、chosenとの差が最大となる応答をrejectedとした。各設定で500組の選好ペアを用いた。

BASiS内部のLLM処理にはResponses APIを使用した。工程1のコーパス分析と確率推定にはgpt-5.4-pro, 工程3の観測ラベル付与にはgpt-5.4を用い、いずれもtemperatureを1.0, reasoning effortをhighに設定した。LLM評価には、後述する別の設定を用いた。

表2に四条件を示す。Baseは追加学習前のモデル、Target-onlyは小規模高品質コーパスのみでDPO学習したモデル、BASiSは対話進行適合度スコアで選別したデータを用いるモデル、Randomはキーワードで絞り込んだカテゴリから無作為に選んだデータを用いるモデルである。すべてQwen3.5-27Bを用い、Target-only, BASiS, RandomにはLoRAによるDPO学習を行った。BASiSとRandomでは学習データ数、選好データ形式、学習設定を揃えた。DPOの学習率は 5×10^{-6} , $\beta = 0.1$, LoRAは $r = 8$, $\alpha = 16$, dropoutは0.05とし、1エポック学習した。

BASiSとBaseの比較によってRQ1を検証する。BASiSとRandomの比較はRQ2の中心的な検証であり、両条件の主な違いは、参照コーパスから得た対話進行をchosen応答の選別に用いるかどうかである。Target-onlyはLLM評価にのみ含める診断的条件であり、現在利用できる小規模コーパスを直接学習するだけで十分

Table 3. 各対話設定における人手評価項目（7段階；1＝全く当てはまらない，7＝非常によく当てはまる）

項目	質問文
コーパスペア：ESConv × DailyDialog	
Q1	相談者を支える応答として，全体的に良い。
Q2	相談者の気持ちを受け止め，やさしく話している。
Q3	これまでの会話に合った，支える立場の話し方を続けている。
Q4	相手の話を理解・整理しようとし，指示や結論をすぐに押しつけていない。
Q5	この会話の段階に対して，助言や提案を出すタイミングが適切である。
Q6	これまでの話の内容によく合っている。
Q7	会話として自然で読みやすい。
最終選択	気持ちを受け止め，安心して話を続けられる支援応答として最も適切なものを選ぶ。
コーパスペア：MathDial × WildChat-1M	
Q1	学習者が自分で考え，説明し，解き方を試せる余地を残している。
Q2	学習者の考えが正しいか，どこが誤り・不十分かを正確に捉えている。
Q3	次に見直すべき箇所や考えるべき点を，具体的に絞っている。
Q4	質問，ヒント，説明が正確で，学習者の現在の理解に合っている。
Q5	学習者が次に何を考え，計算し，確かめればよいか分かる。
Q6	答えや解き方を示す量とタイミングが，会話の進み具合に合っている。
Q7	質問，ヒント，説明，理解確認の使い分けが，会話の段階に合っている。
最終選択	学習者の考えを捉え，自力で次に進めるよう支える個別指導応答として最も適切なものを選ぶ。
コーパスペア：MediTOD × WildChat-1M	
Q1	すでに分かっている内容を不必要に聞き直さず，新しい必要情報を集めている。
Q2	情報がまだ足りない段階では，診断や対応を急いでいない。
Q3	分かっていることを断定せず，確かめる必要があることを適切に扱っている。
Q4	情報が十分でないのに，薬・治療・受診方法を強く決めつけて指示していない。
Q5	十分な根拠がないのに，病名や症状の原因を決めつけていない。
最終選択	必要な情報を集め，断定を避けて安全に進める医療者応答として最も適切なものを選ぶ。

かを確認する．学習データの出所とペア数がBASiSと異なるため，この比較によってベイズ的モデル化だけの効果が分離されるとは解釈しない．

4.2.3 人手評価． 人手評価では，各設定に必要な対話進行が生成応答に適切に表れていると人間が判断するかを直接検証した．BaseとBASiSの比較によってRQ1を，BASiSとRandomの比較によってRQ2を検証する．参加者の負担を抑えるためTarget-onlyは含めず，直接学習条件は検証しない．研究室メンバー9名を対象とし，各設定10件の対話文脈で三条件を比較した．応答をA-Cとしてモデル名を伏せ，同じ条件が常に同じ記号にならないよう対応を入れ替えた．評価者は表3の質問について，各応答を1（全く当てはまらない）から7（非常によく当てはまる）の7段階で評価し，最後に最も適切な応答，または「ほぼ同じ」「判断できない」を選択した．ESConvとMathDialでは9名全員，MediTODでは未完了回答者2名を除く7名の回答を分析した．

項目ごとに各参加者の10件の平均値を算出し，参加者を分析単位とした．Friedman検定とKendallのWを用い，有意な項目では三組の対応あり置換検定にHolm補正を適用した．95%信頼区間は参加者単位のブートストラップを2,000回行って算出した．最終選択は反復回答であるため，件数と割合を記述統計として報告する．

最終選択の選択肢は，三領域で共通して「応答A」「応答B」「応答C」「ほぼ同じ」「判断できない」とした．

4.2.4 LLMによる大規模評価． 各設定100件の対話文脈を対象に，Base，Target-only，BASiS，Randomを比較した．これは，LLMを評価者として用いるLLM-as-a-judge方式の評価である．これにより，小規模コーパスの直接学習と，大規模コーパスからの対話進行に基づく選別を診断的に比較する．四条件で同じ対話文脈を用い，モデル名を伏せて提示順をランダム化した．評価LLMにはGPT-5.4を用い，temperatureを0に設定

Table 4. 各対話設定におけるLLM評価軸（1-10点；すべて高いほど望ましい）

評価軸	評価内容
コーパスペア：ESConv × DailyDialog	
ESConv Support Behavior Strength	ESConvに特徴的な共感的支援行動の明確さ
ESConv Tone Similarity	温かく受容的で非断定的な語調のESConv類似度
Supporter Role Consistency	支援者の役割を保ち、説教・自己開示・逸脱を避ける度合い
Non-directive Support	意思を尊重し、断定や押し付けを避ける度合い
Strategy/Stage Alignment	応答戦略とその時点の会話段階との適合
Premature Advice Avoidance	感情・状況を理解してから助言へ移る適切さ
Naturalness	文脈に合った自然な会話としての成立度
コーパスペア：MathDial × WildChat-1M	
Equitable Tutoring	学習者が自ら考え、説明し、解法を探索する余地
Learner Reasoning Diagnosis	学習者の推論の正誤・不足・混乱の把握
Mistake Location and Targeting	推論の誤りや未完了箇所の正確な特定
Guidance Quality	質問・ヒント・説明・例の正確さと有用性
Feedback Actionability	次に考え、計算し、確認すべき行動の明確さ
Answer Revealing Calibration	解答を示す量・時機と理解状態・会話段階の適合
Teacher Move-Stage Alignment	教師の応答戦略と会話段階の適合
コーパスペア：Medi TOD × WildChat-1M	
Response Relevance	直前までの症状・背景に即した質問・応答の関連性
Overall Quality	関連性・明瞭さ・自然さ・情報収集への有用性
Premature Assessment Avoidance	情報不足時に診断・治療方針を急がない度合い
Appropriate Uncertainty	不確実性と追加確認の必要性を適切に示す度合い
Understandability	専門用語を抑えた明確で理解しやすい質問・説明
Unsafe Medical Advice Avoidance	有害となり得る不適切な医学的助言を避ける度合い
Unsupported Diagnosis Avoidance	根拠不足時に特定の疾患・原因の断定を避ける度合い

した．会話履歴と評価対象応答に加え，表4の各軸について，定義，高得点・低得点の条件，共通の採点基準を提示した．1-2点を明確に不適切，3-4点を適合が弱い，5-6点を最低限満たす，7-8点を十分に満たす，9-10点を改善点が少ない応答とし，10点はほぼ理想的な応答に限定した．モデル名や応答長だけで判断しないよう指示し，軸別の整数値，総合値，および短い根拠を出力させた．

ESConvでは支援行動，語調，支援者役割，非指示性，会話段階との適合，助言の時機，自然さを評価する[6, 9, 19]．MathDialでは，学習者の推論を促し，誤りを診断し，質問・ヒント・説明・解答提示を段階に応じて使い分けられるかを評価する[8]．Medi TODでは，問診の適切さ，応答品質，医学的安全性を評価する[14]．Unsafe Medical Advice AvoidanceとUnsupported Diagnosis Avoidanceは望ましくない行動を回避する度合いであり，他の軸と同様に高得点ほど望ましい．各軸についてFriedman検定を行い，有意な場合は六組の対応あり置換検定に軸内Holm補正を適用した．有意水準は $\alpha = .05$ とし，平均値にはブートストラップ95%信頼区間を示した．

4.3 人手評価結果

BASiSは人手評価の全19項目で最高平均値を示し，BaseとRandomをそれぞれ16項目で有意に上回り，三設定すべてで最終選択として最も多く選ばれた．

感情支援.




Fig. 3. ESConvとDailyDialogにおける人手評価結果。棒は参加者ごとの10件の平均値，エラーバーは参加者単位のブートストラップ95%信頼区間を表す。括弧はHolm補正後の有意なBASiSとの比較を表す（* $p < .05$ ，** $p < .01$ ）。




Fig. 4. MathDialとWildChat-1Mにおける人手評価結果。棒とエラーバーは参加者ごとの平均値とブートストラップ95%信頼区間を表す。括弧はHolm補正後の有意なBASiSとの比較を表す（* $p < .05$ ，** $p < .01$ ）。

図3に示すように，BASiSは七項目すべてで最高平均値を示し，助言のタイミングを除く六項目でBaseとRandomを有意に上回った．支援行動の強さはBase，BASiS，Randomの順に4.22，5.64，3.97，語調の類似度は4.59，6.17，4.43であり，有意な項目のKendallのWは.479-.876であった．助言のタイミングもBASiSが最高平均値だったが，対応比較は有意ではなかった．最終選択率は74.4%であった．

数学チュータリング．

図4では，BASiSが七項目すべてでBaseとRandomを有意に上回った．学習者の思考を促す項目は4.28，5.42，3.73，次の行動の明確さは4.13，5.43，3.72であり，KendallのWは.716-.939であった．最終選択率は61.1%であった．

医療問診．

図5では，BASiSが五項目すべてで最高平均値を示した．診断や対応を急がないこと，危険な医学的助言を避けること，根拠のない診断を避けることの三項目でBaseとRandomを有意に上回り，KendallのWは.799-.813であった．情報の重複回避と不確実性の扱いに関する項目では，Friedman検定が有意ではなかった．最終選択率は44.3%で最も高かった．

表5に最終選択の分布を示す．BASiSはESConvで74.4%，MathDialで61.1%，MediTODで44.3%となり，三設定すべてで最多であった．MediTODでは過半数ではないが，Randomを17.2ポイント上回った．

4.4 LLM評価結果

BASiSはLLM評価の全21軸で最高平均値を示し，Baseに18軸，Target-onlyに13軸，Randomに15軸で有意に上回った．Target-onlyがBaseを有意に上回った軸はなかった．

感情支援．

図6では，BASiSが全七軸で最高平均値を示した．支援行動の強さはBase，Target-only，BASiS，Randomの順に8.26，8.22，8.65，8.21，語調の類似度は8.21，8.25，8.52，8.13であり，BASiSは両軸で三条件すべてを有意に上回った．Premature Advice Avoidanceも8.57，8.76，9.44，8.92となり，三条件すべてとの差が有意であった．NaturalnessはRandomを有意に上回った．




Fig. 5. MediTODとWildChat-1Mにおける人手評価結果．棒とエラーバーは完全回答者7名の平均値と参加者単位のブートストラップ95%信頼区間を表す．括弧はHolm補正後の有意なBASiSとの比較を表す (* $p < .05$) ．

Table 5. 人手評価における最終選択の件数と割合

選択	ESConv	MathDial	MediTOD
Base	14 (15.6%)	16 (17.8%)	11 (15.7%)
BASiS	67 (74.4%)	55 (61.1%)	31 (44.3%)
Random	6 (6.7%)	12 (13.3%)	19 (27.1%)
ほぼ同じ	2 (2.2%)	3 (3.3%)	8 (11.4%)
判断できない	1 (1.1%)	4 (4.4%)	1 (1.4%)




Fig. 6. ESConvとDailyDialogにおけるLLM評価結果．棒は平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧は六組の比較に対するHolm補正後の有意なBASiSとの比較を表す (* $p < .05$, ** $p < .01$, *** $p < .001$) ．




Fig. 7. MathDialとWildChat-1MにおけるLLM評価結果．棒は平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧は六組の比較に対するHolm補正後の有意なBASiSとの比較を表す (すべて*** $p < .001$) ．

数学チュータリング．

図7では，BASiSが七軸すべてで三条件を有意に上回った (すべて $p < .001$) ．学習者の思考を促す軸は6.77, 7.02, 7.75, 6.00, 推論の診断は7.38, 7.76, 8.70, 6.97, 誤りの特定は7.53, 7.74, 8.85, 7.27であった．次の行動の明確さにおけるBASiSとRandomの差は1.85ポイントで最大だった．Target-onlyは全軸でBaseより高かったが，差は有意ではなかった．

医療問診．




Fig. 8. MediTODとWildChat-1MにおけるLLM評価結果．棒は平均値，エラーバーはブートストラップ95%信頼区間を表す．括弧は六組の比較に対するHolm補正後の有意なBASiSとの比較を表す (* $p < .05$, ** $p < .01$) ．

図8では，BASiSが全七軸で最高平均値を示した．応答の関連性は4.46，4.70，5.09，4.91，総合品質は5.16，5.26，5.69，5.46であった．不確実性の適切な扱いは7.84，7.96，8.26，7.92となり，BASiSは三条件すべてを有意に上回った．また，危険な医学的助言の回避でRandomを，根拠のない診断の回避でBaseとRandomを有意に上回った．Target-onlyはMediTODでもBaseを有意に上回らなかった．

4.5 考察

4.5.1 対話進行の反映に対する有効性．RQ1について，BASiSは三設定すべてで参照コーパスの対話進行を生成応答へ反映したと考えられる．感情支援では感情を受け止めてから助言し，数学チューティングでは理解を診断してから足場を与え，医療問診では情報を収集・確認してから判断するという形で現れた．人手評価では全項目で最高平均値を示し，三設定すべてで最終選択が最多であり，LLM評価でも全21軸で同じ方向が確認された．これは単語や単一ターンの品質だけでなく，展開中の対話でいつ応答戦略を用いるかが反映されたことを示す．式(3)のように，履歴，状態遷移，観測ラベルから得た事後確率で候補を評価することで，各参照コーパスに含まれる応答の順序やタイミングを学習できたと考えられる．

4.5.2 対話進行に基づくデータ選別の寄与．RQ2について，BASiSはRandomを人手評価の19項目中16項目で有意に上回り，LLM評価では全21軸で高い平均値を示して15軸で有意に上回った．両条件はデータ量・形式と学習設定を揃え，候補集合も粗い話題で絞り込んでいるため，この差はDPO学習や話題の一致を超えて，対話進行に基づく選別が寄与したことを示す．会話状態，応答戦略，遷移を用いることで，話題が合うだけの応答と，適切な時点で対話を前進させる応答を区別できたと考えられる．

Target-onlyはLLM評価のどの軸でもBaseを有意に上回らず，BASiSはTarget-onlyを13軸で上回った．したがって，本設定では，小規模コーパスを嗜好データの唯一の供給源とするより，大規模コーパスを選ぶ基準の抽出元として用いる方が有効だったと考えられる．ただし，Target-onlyはデータの出所とペア数が異なり，人手評価にも含まれないため，ベイズ的モデル化だけの寄与を分離する比較ではない．

4.5.3 適用範囲と限界. 参照コーパスと候補コーパスを変更することで、同じBASiSパイプラインを三設定へ適用できた。同じ傾向が繰り返し確認されたことは、異なる対話進行への適用可能性を支持するが、未知の設定や利用者への一般化を示すものではない。人手評価は研究室内の9名を対象とし、MediTODの完全回答者は7名、各設定は10文脈であった。LLM評価は100文脈を扱う一方、単一の評価LLMに依存し、人手評価と評価項目も完全には一致しない。また、Target-onlyはBASiSとデータ量を揃えたアプレーションではない。今後は、外部評価者と対話文脈を増やし、複数の評価LLM、評価項目の整合、データ量を揃えた比較を導入する必要がある。

5 結論

本研究では、小規模高品質コーパスの対話進行を、ベイズ的データ選別によってLLMへ反映する手法BASiSを提案した。BASiSは、ラベルの個数と役割に明示的な制約を設けた上で、LLMにより小規模コーパスから会話状態、応答戦略、状態遷移、確率の推定値を導出し、ベイズ的対話モデルとして定式化する。このモデルを用いて大規模汎用コーパスの候補応答を評価し、得られた選好データによってLoRAアダプタを学習する。この仕組みにより、目的ごとの詳細な対話ガイドラインを手で記述することなく、小規模コーパスに含まれる応答戦略と複数ターンにわたる対話の進め方を、学習データの選別基準として利用できる。また、会話状態を確率分布として扱い、候補応答から得た観測によって更新することで、会話履歴と応答後の状態遷移を考慮して目的に適したデータを選別できる。

感情支援、数学チュータリング、医療問診の三設定における評価では、人手評価の全19軸でBASiSが最高平均値を示し、三設定すべての最終選択で最も多く選ばれた。LLMによる大規模評価でも全21軸で最高平均値を示した。これらの結果から、共感的な支援戦略、学習者の理解状態に応じた教育的支援、および情報不足時に断定を避ける応答戦略を、各設定のコーパスに応じてモデルへ反映できる可能性が示された。また、LLM評価ではTarget-onlyがBaseを有意に上回る軸がなく、Randomとの比較でもBASiSが広い範囲で優位であったことから、小規模コーパスを相互作用上の知識の抽出元として活用し、粗い話題の一致を超えて学習データを選ぶことの重要性が示された。

今後は、異なるモデルへの適用可能性を評価するとともに、対話領域に応じた会話状態・応答戦略・望ましい状態群の設計方法を検討する。さらに、外部評価者とより多くの対話例を用いた人手評価を行い、カウンセリング、教育、医療をはじめとする多様な対話領域への応用可能性を検証する。

References

- [1] Lichang Chen, Shiyang Li, Jun Yan, Hai Wang, Kalpa Gunaratna, Vikas Yadav, Zheng Tang, Vijay Srinivasan, Tianyi Zhou, Heng Huang, and Hongxia Jin. 2024. AlpGasus: Training a Better Alpaca with Fewer Data. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=FdVXgSJhvz>
- [2] Ananya Ganesh, Martha Palmer, and Katharina Kann. 2021. What Would a Teacher Do? Predicting Future Talk Moves. In *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*. Association for Computational Linguistics, Online, 4739–4751. doi:10.18653/v1/2021.findings-acl.418
- [3] Prakhar Gupta, Yang Liu, Di Jin, Behnam Hedayatnia, Spandana Gella, Sijia Liu, Patrick Lange, Julia Hirschberg, and Dilek Hakkani-Tur. 2023. DialGuide: Aligning Dialogue Model Behavior with Developer Guidelines. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 14031–14047. doi:10.18653/v1/2023.findings-emnlp.935
- [4] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2022. LoRA: Low-Rank Adaptation of Large Language Models. The Tenth International Conference on Learning Representations (ICLR 2022). <https://openreview.net/forum?id=nZvKeeFYf9>
- [5] Yanran Li, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. DailyDialog: A Manually Labelled Multi-turn Dialogue Dataset. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Asian Federation of Natural Language Processing, Taipei, Taiwan, 986–995. <https://aclanthology.org/I17-1099/>
- [6] Siyang Liu, Chujie Zheng, Orianna Demasi, Sahand Sabour, Yu Li, Zhou Yu, Yong Jiang, and Minlie Huang. 2021. Towards Emotional Support Dialog Systems. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on*

- Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, Online, 3469–3483. doi:10.18653/v1/2021.acl-long.269
- [7] Wei Liu, Weihao Zeng, Keqing He, Yong Jiang, and Junxian He. 2024. What Makes Good Data for Alignment? A Comprehensive Study of Automatic Data Selection in Instruction Tuning. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=BTKAeLqLMw>
- [8] Jakub Macina, Nico Daheim, Sankalan Pal Chowdhury, Tanmay Sinha, Manu Kapur, Iryna Gurevych, and Mrinmaya Sachan. 2023. MathDial: A Dialogue Tutoring Dataset with Rich Pedagogical Properties Grounded in Math Reasoning Problems. In *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, Singapore, 5602–5621. doi:10.18653/v1/2023.findings-emnlp.372
- [9] Remi Mir, Bjarke Felbo, Nick Obradovich, and Iyad Rahwan. 2019. Evaluating Style Transfer for Text. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Association for Computational Linguistics, Minneapolis, Minnesota, 495–504. doi:10.18653/v1/N19-1049
- [10] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. 2022. Training Language Models to Follow Instructions with Human Feedback. In *Advances in Neural Information Processing Systems*, Vol. 35. Curran Associates, Inc., Red Hook, NY, USA, 27730–27744.
- [11] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. 2023. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 53728–53741. doi:10.52202/075280-2338
- [12] Hannah Rashkin, Eric Michael Smith, Margaret Li, and Y-Lan Boureau. 2019. Towards Empathetic Open-domain Conversation Models: A New Benchmark and Dataset. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Florence, Italy, 5370–5381. doi:10.18653/v1/P19-1534
- [13] Eric Rudolph, Philipp Steigerwald, and Jens Albrecht. 2026. Transition-Matrix Regularization for Next Dialogue Act Prediction in Counselling Conversations. In *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics, San Diego, California, United States, 25442–25457. doi:10.18653/v1/2026.findings-acl.1271
- [14] Vishal Vivek Saley, Goonjan Saha, Rocktim Jyoti Das, Dinesh Raghu, and Mausam. 2024. MediTOD: An English Dialogue Dataset for Medical History Taking with Comprehensive Annotations. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Miami, Florida, USA, 16843–16877. doi:10.18653/v1/2024.emnlp-main.936
- [15] Chenwei Wan, Matthieu Labeau, and Chloé Clavel. 2025. EmoDynamix: Emotional Support Dialogue Strategy Prediction by Modelling Mixed Emotions and Discourse Dynamics. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Association for Computational Linguistics, Albuquerque, New Mexico, 1678–1695. doi:10.18653/v1/2025.naacl-long.81
- [16] Xiangyu Wen, Jianyuan Zhong, Zhijian Xu, and Qiang Xu. 2025. Guideline Compliance in Task-Oriented Dialogue: The Chained Prior Approach. In *Findings of the Association for Computational Linguistics: NAACL 2025*. Association for Computational Linguistics, Albuquerque, New Mexico, 6765–6791. doi:10.18653/v1/2025.findings-naacl.377
- [17] Mengzhou Xia, Sadhika Malladi, Suchin Gururangan, Sanjeev Arora, and Danqi Chen. 2024. LESS: Selecting Influential Data for Targeted Instruction Tuning. In *Proceedings of the 41st International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 235)*. PMLR, Vienna, Austria, 54104–54132. <https://proceedings.mlr.press/v235/xia24c.html>
- [18] Bolin Zhang, Jiahao Wang, Qianlong Du, Jiajun Zhang, Zhiying Tu, and Dianhui Chu. 2025. A Survey on Data Selection for LLM Instruction Tuning. *Journal of Artificial Intelligence Research* 83, Article 32 (2025), 14 pages. doi:10.1613/jair.1.17625
- [19] Saizheng Zhang, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela, and Jason Weston. 2018. Personalizing Dialogue Agents: I have a dog, do you have pets too?. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, Melbourne, Australia, 2204–2213. doi:10.18653/v1/P18-1205
- [20] Wenting Zhao, Xiang Ren, Jack Hessel, Claire Cardie, Yejin Choi, and Yuntian Deng. 2024. WildChat: 1M ChatGPT Interaction Logs in the Wild. The Twelfth International Conference on Learning Representations (ICLR 2024). <https://openreview.net/forum?id=Bl8u7ZRIbM>
- [21] Chunting Zhou, Pengfei Liu, Puxin Xu, Srini Iyer, Jiao Sun, Yuning Mao, Xuezhe Ma, Avia Efrat, Ping Yu, Lili Yu, Susan Zhang, Gargi Ghosh, Mike Lewis, Luke Zettlemoyer, and Omer Levy. 2023. LIMA: Less Is More for Alignment. In *Advances in Neural Information Processing Systems*, Vol. 36. Curran Associates, Inc., Red Hook, NY, USA, 55006–55021. doi:10.52202/075280-2400